



UNIVERSITÉ
TOULOUSE 1
CAPITOLE

Intelligence artificielle Machine Learning

Benoit Gaudou

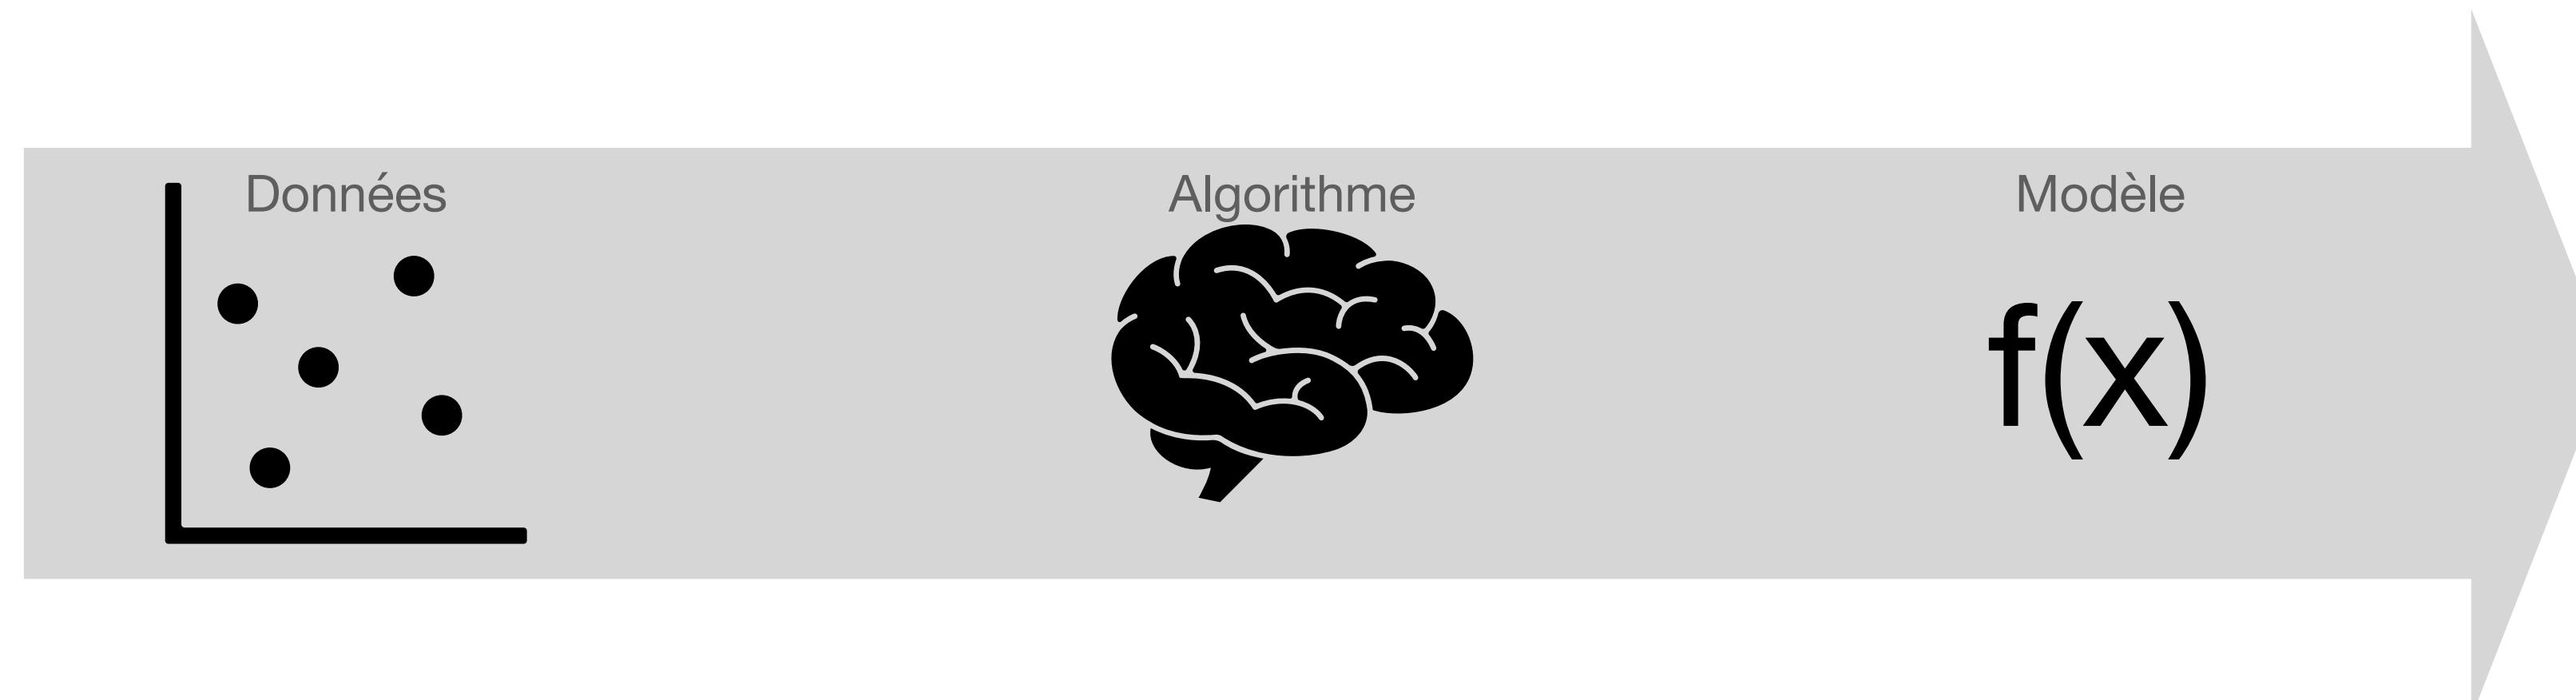
Sylvain Cussat-Blanc

Plan du cours

- Introduction au Machine Learning
- Introduction à l'apprentissage supervisé
 - Notions et définitions
 - 5 algorithmes:
 - K plus proches voisins (kNN)
 - Régression linéaire et logistique
 - Support Vector Machine (SVM)
 - Arbre de décision (Decision Tree)
 - Forêts aléatoires (Random Dorrest)
 - Evaluation des modèles
 - Optimisation paramétrique
 - Point méthodologique

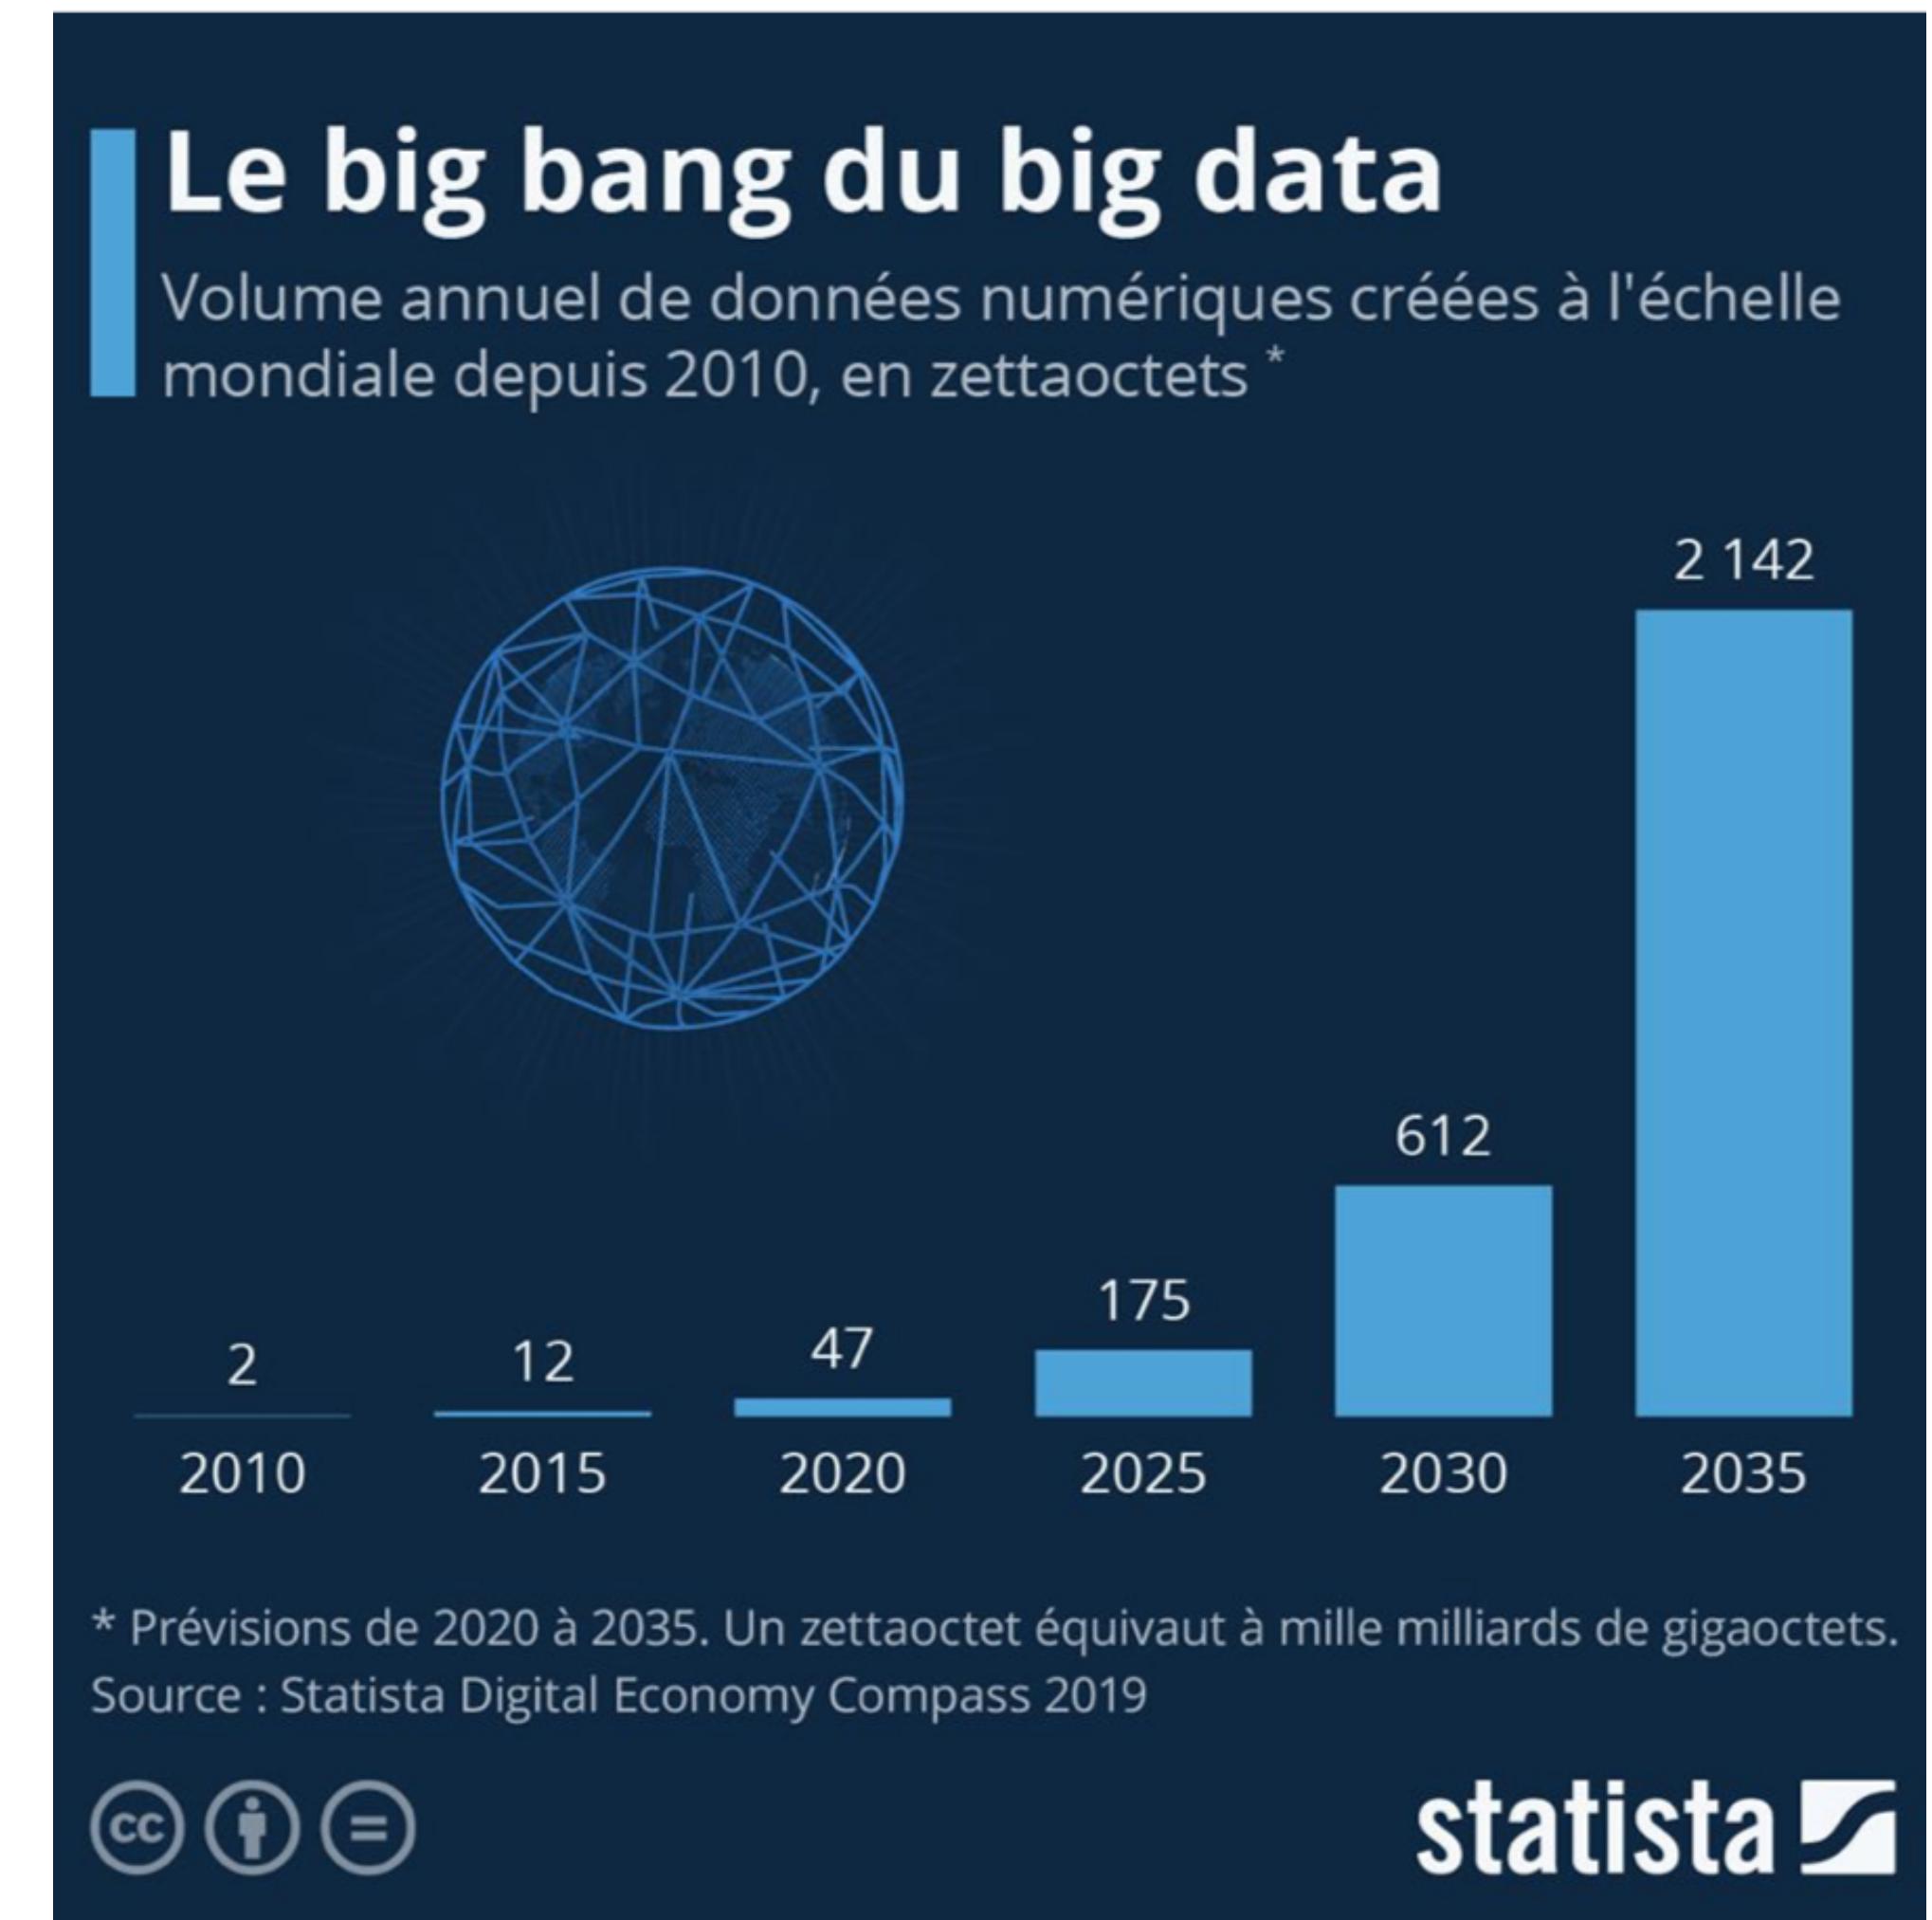
Qu'est-ce que le machine learning ?

- Programmation basé sur les données
 - Capacité des ordinateurs à **apprendre à réaliser une tâche** (classification, détection, traduction, etc.) **sans l'avoir explicitement programmé**
 - Etude des algorithmes qui **améliorent leur performance sur certaines tâches** en se basant sur leur **expérience**



Pourquoi le Machine Learning ?

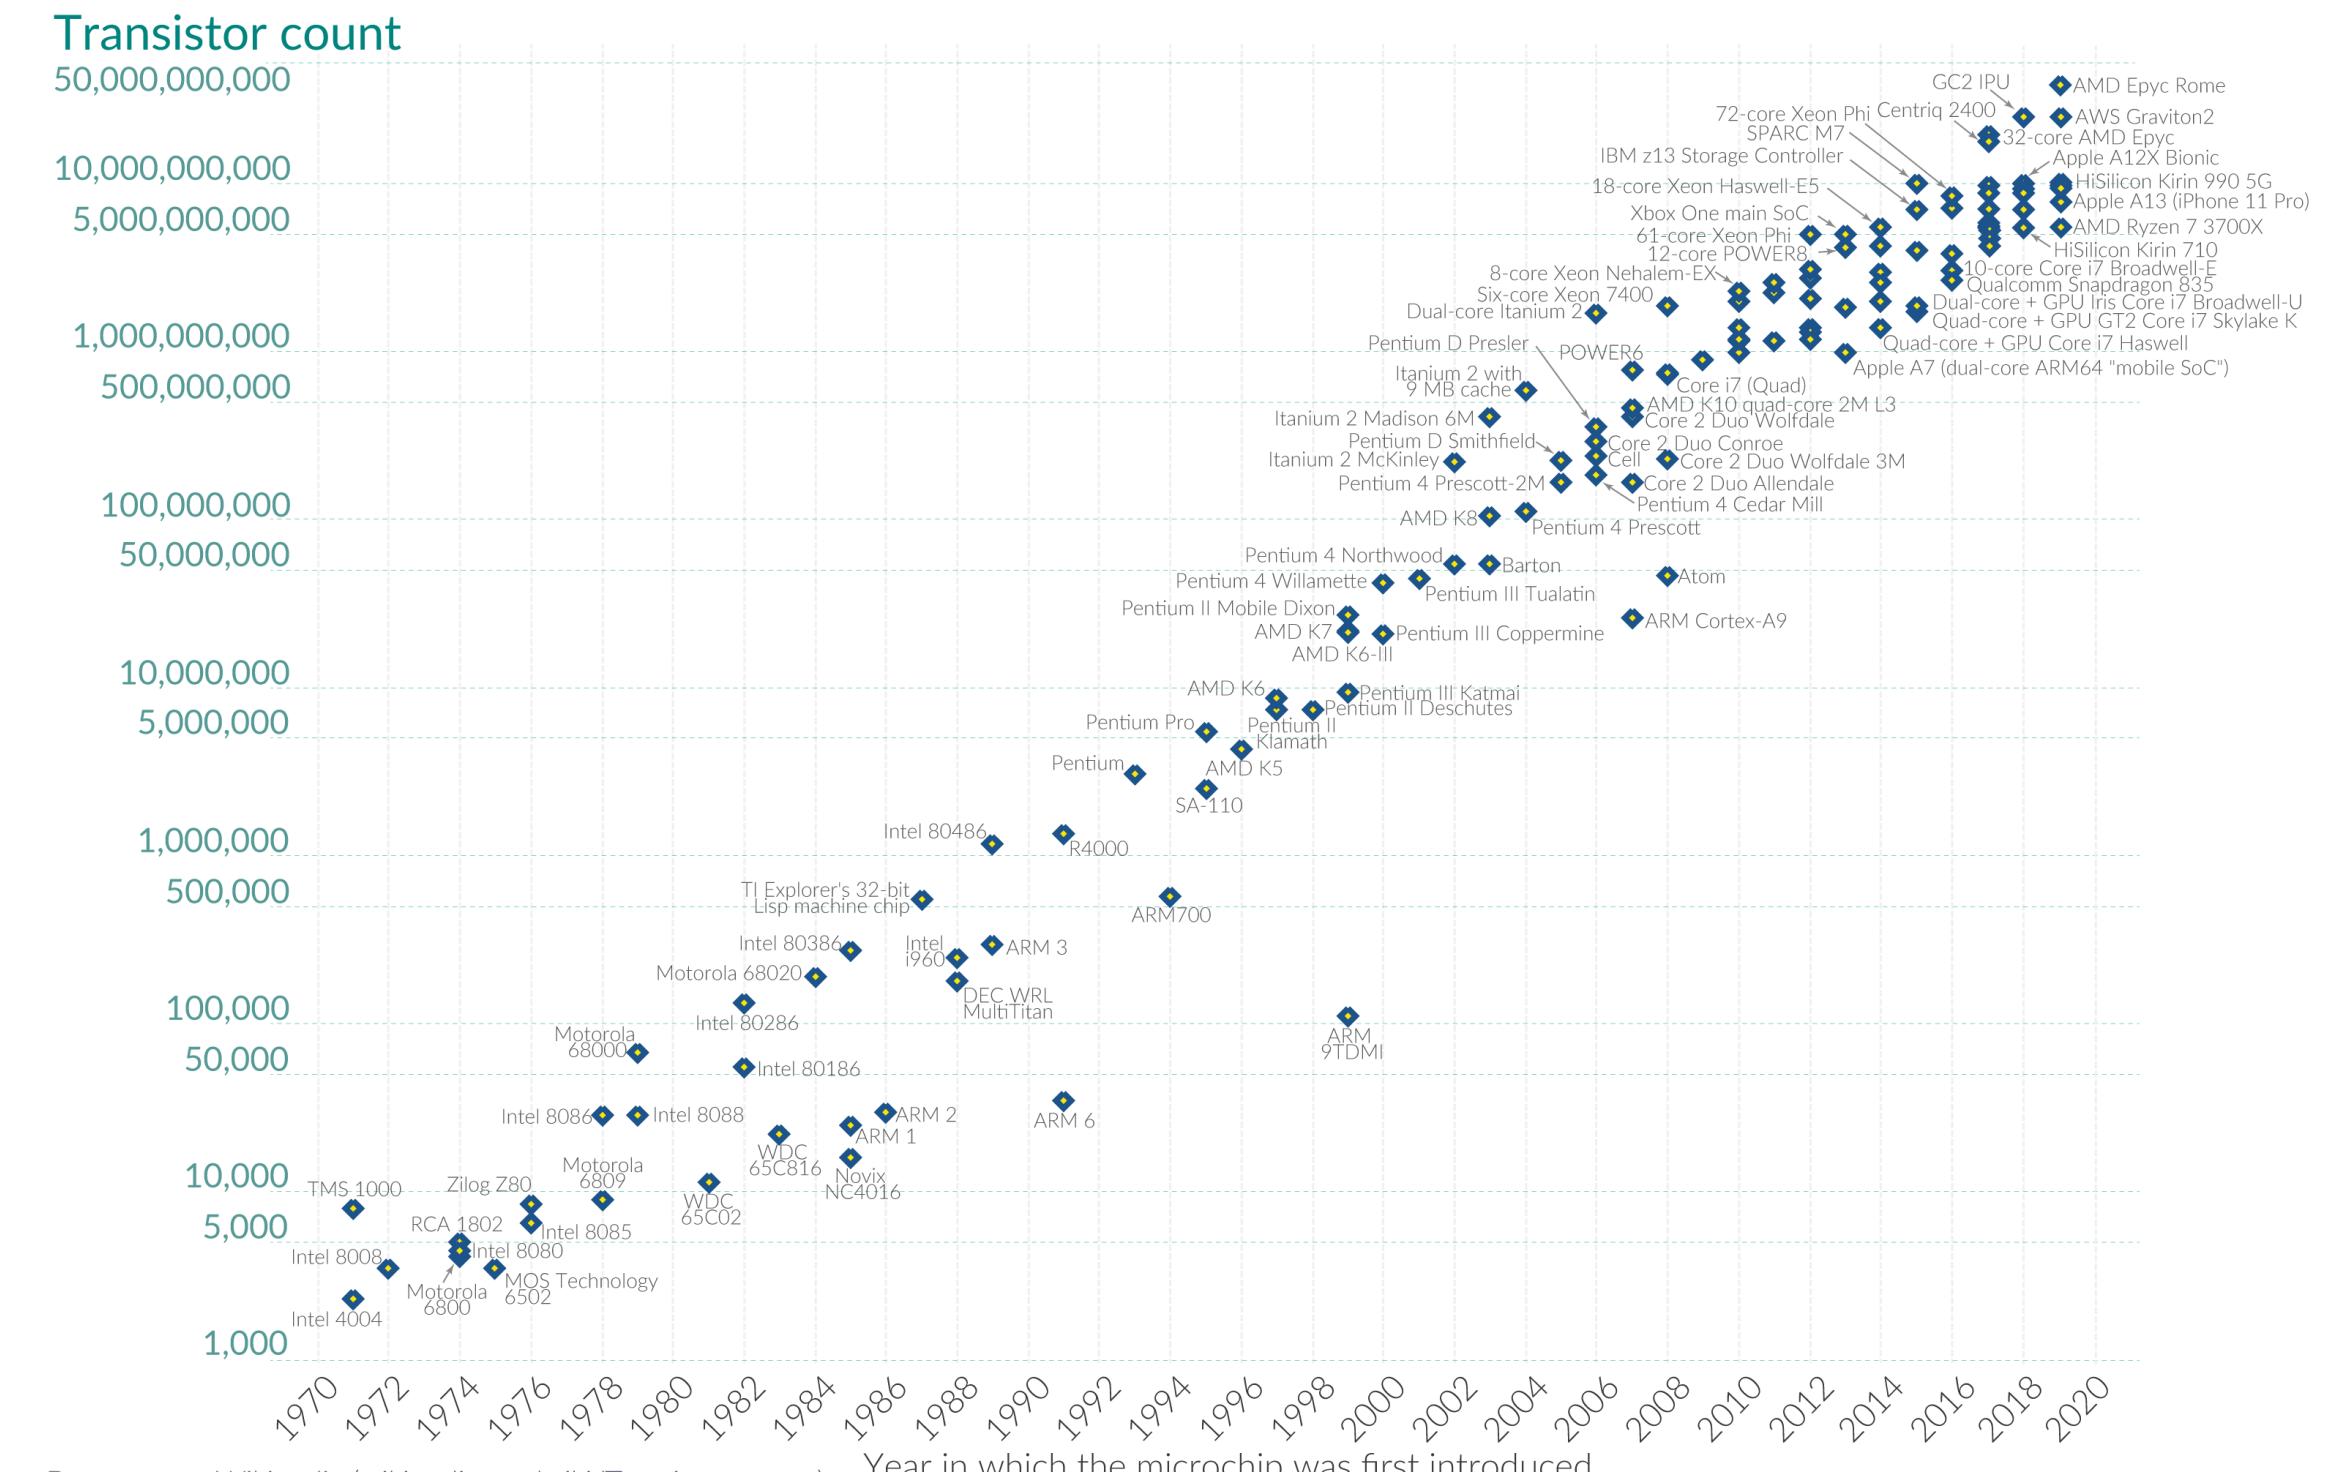
- Disponibilité des données
 - Aire du Big Data : augmentation continue des données générées
 - Twitter : 50M tweets / jour (= 7To/jour)
 - Facebook : 10 To / jour
 - Youtube : 50h de vidéos uploadées par minute
 - 2.9 millions d'emails par secondes



Pourquoi le Machine Learning ?

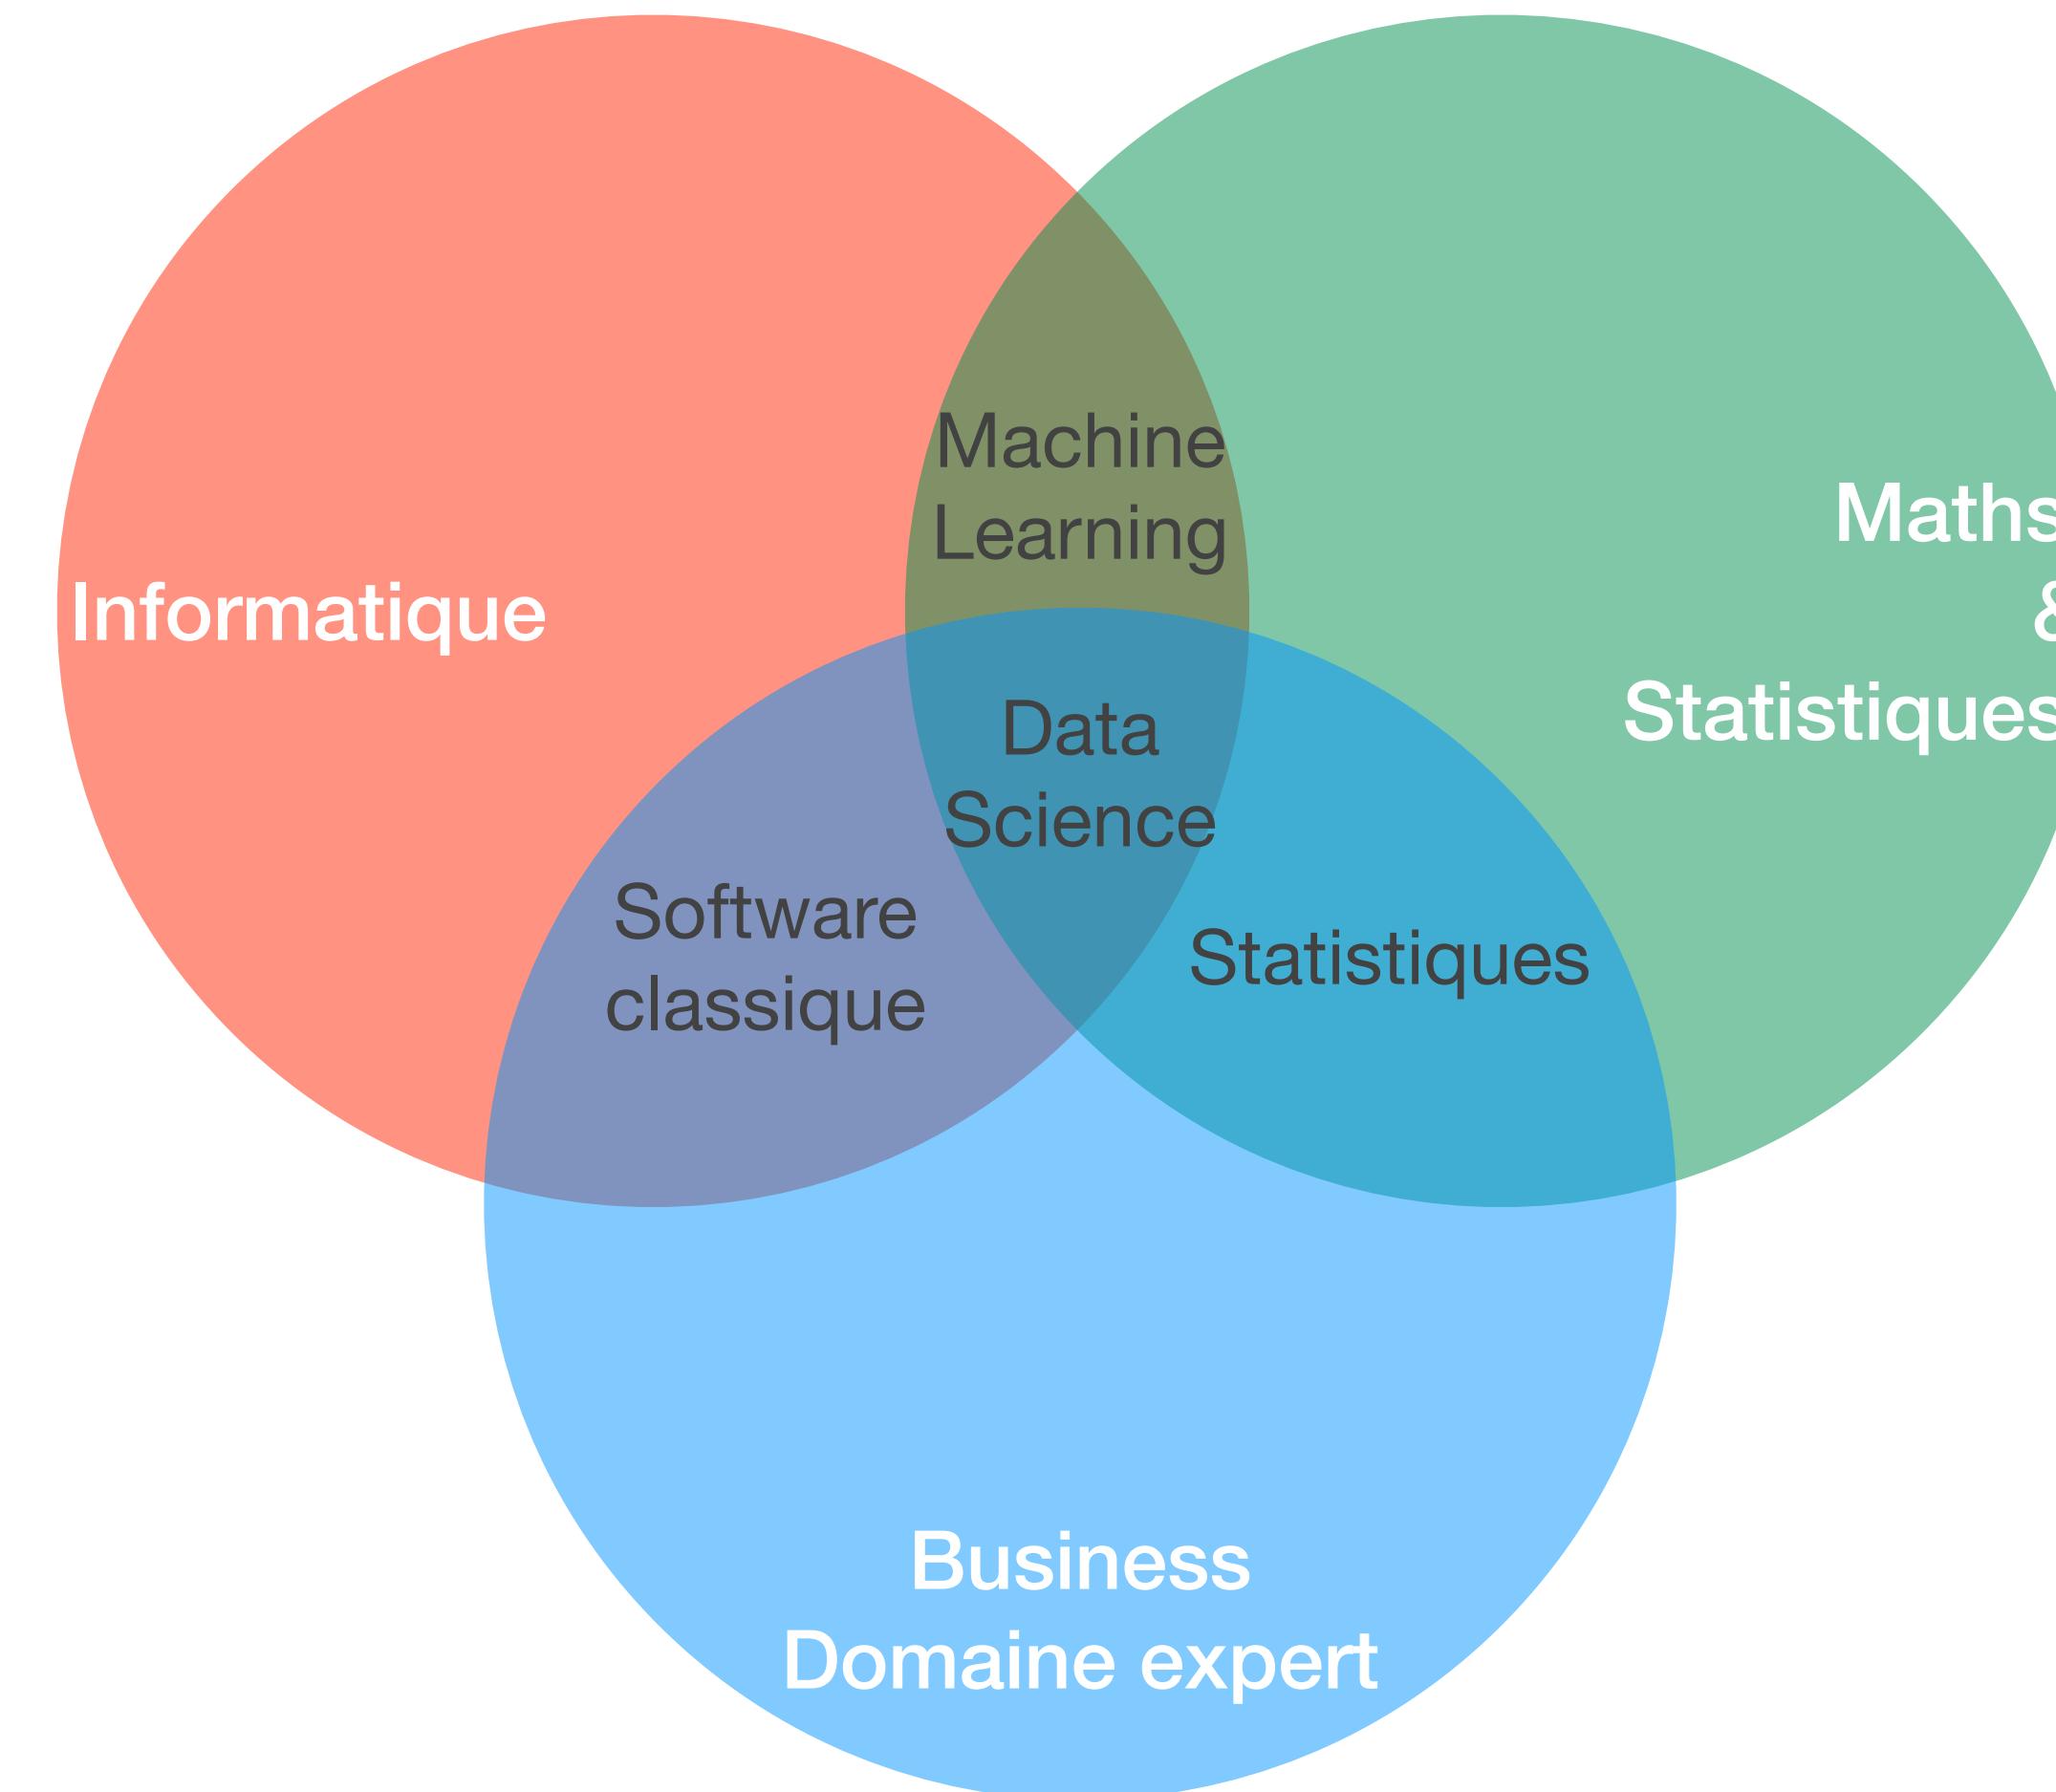
- Augmentation de la puissance de calcul
- Loi de Moore : doublement de la puissance tous les 2 ans
- Calcul parallèle et matriciel

Moore's Law: The number of transistors on microchips doubles every two years
Moore's law describes the empirical regularity that the number of transistors on integrated circuits doubles approximately every two years.
This advancement is important for other aspects of technological progress in computing – such as processing speed or the price of computers.



Licensed under CC-BY by the authors Hannah Ritchie and Max Roser.

Positionnement du Machine Learning



Application du machine learning

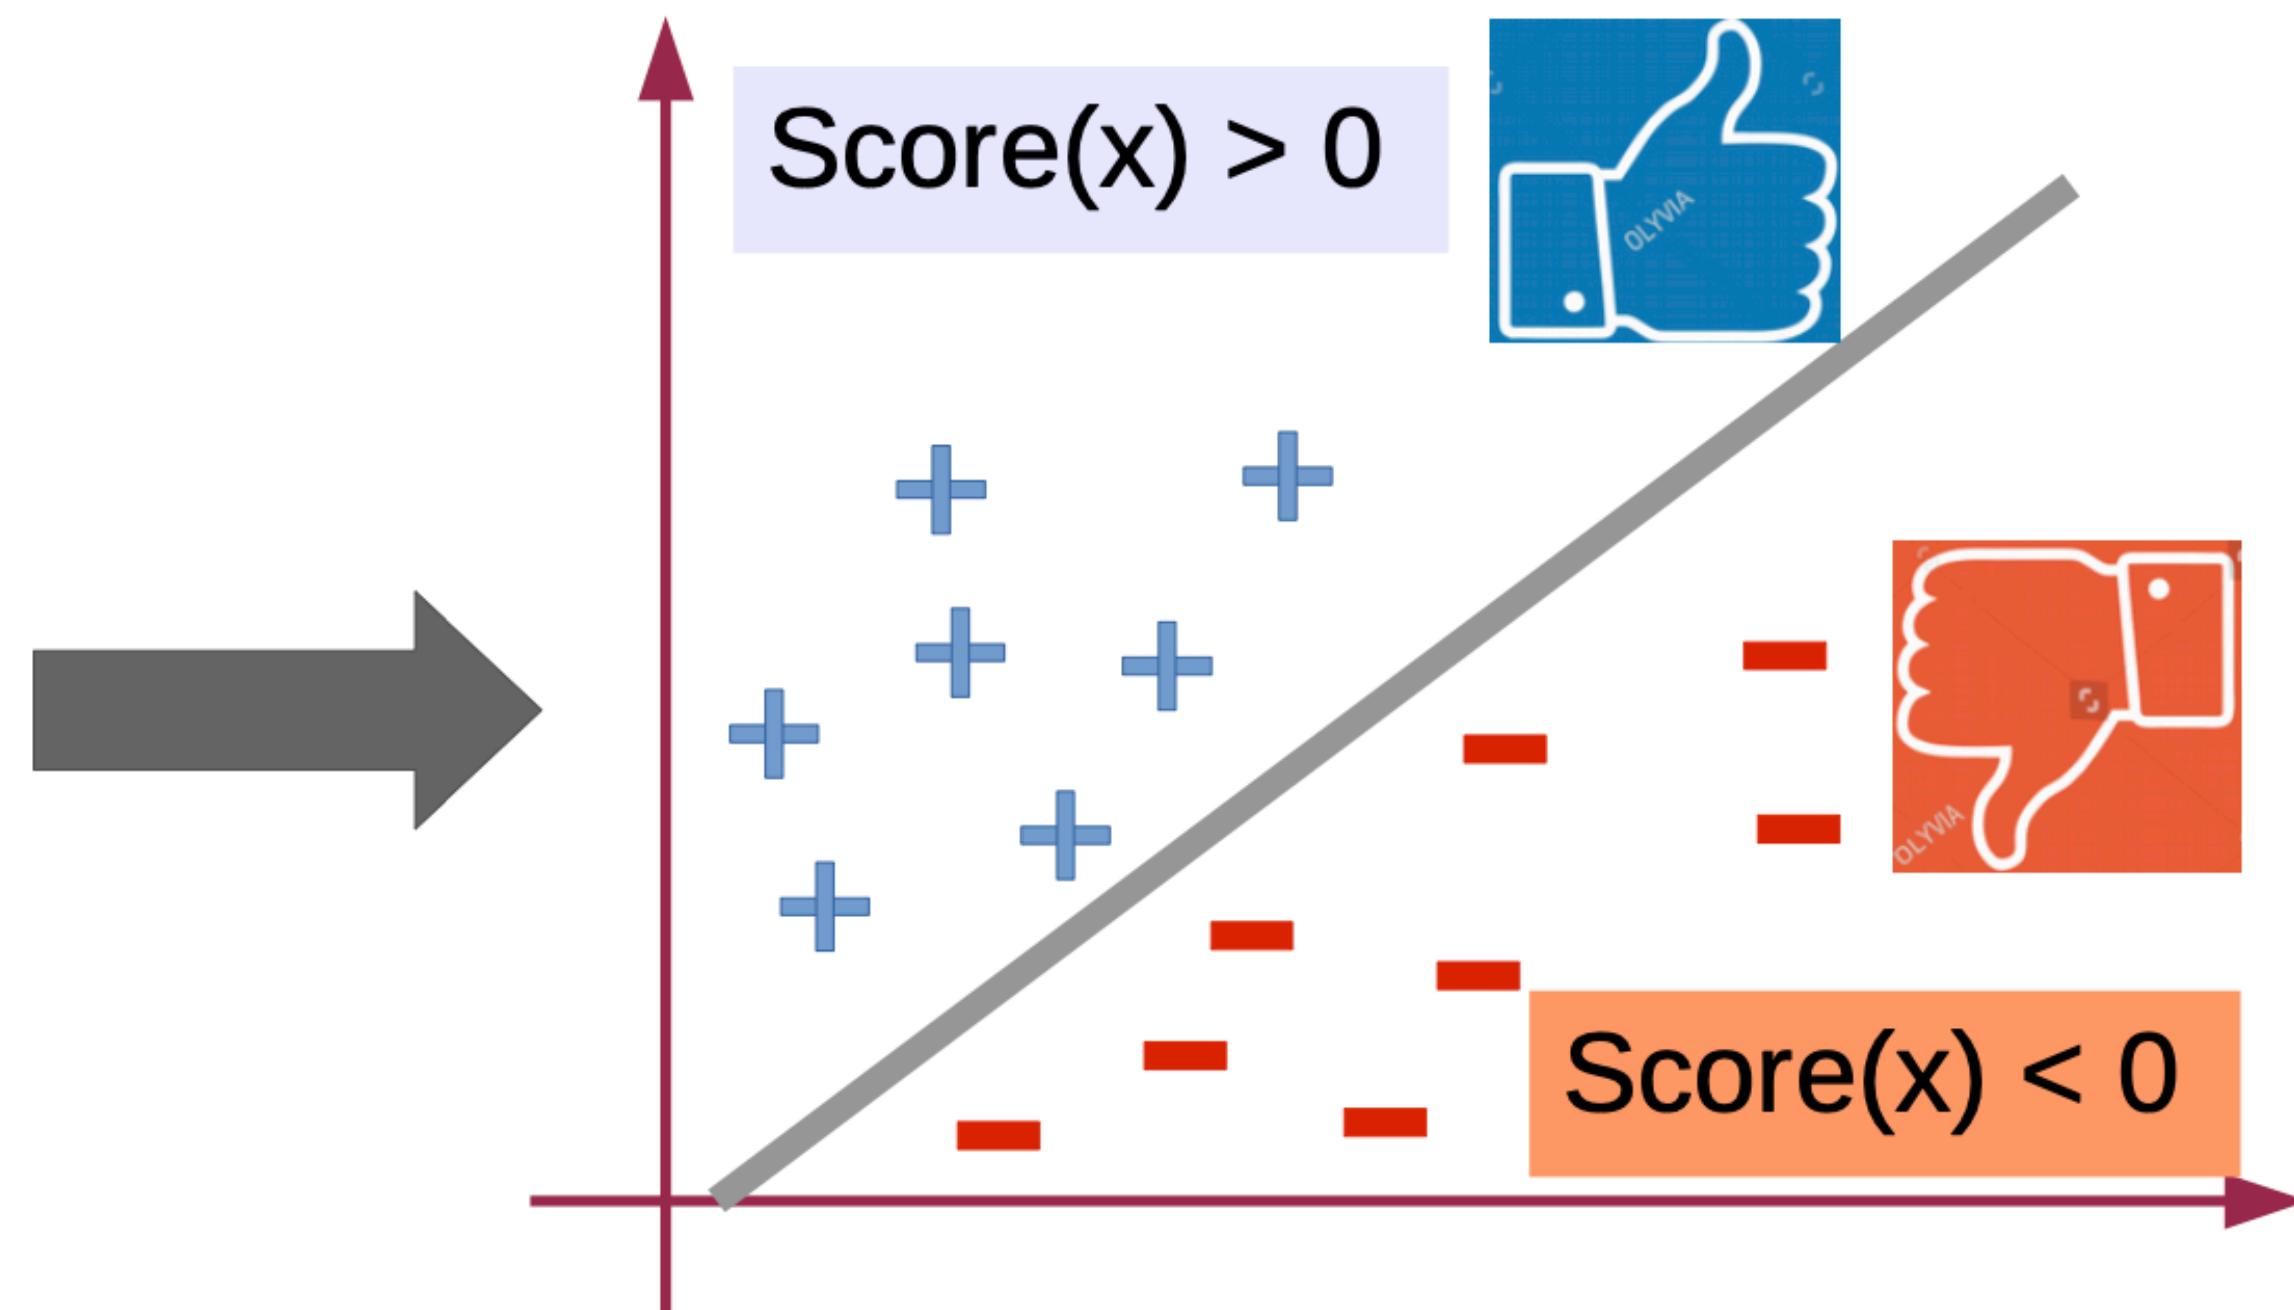
Analyse des sentiments

- Classifier les commentaires des utilisateurs

Here is my review about Tarantino's last movie I've watched last saturday. It was really awesome. I enjoy the characters, the script and the music. I fully recommend everyone to go to theater and enjoy the movie.

Yeah, yeah, what to say about this movie ? It is not that bad, but it is not the top Tarantino's movies. Has some good features (music, landscapes) but also bad features

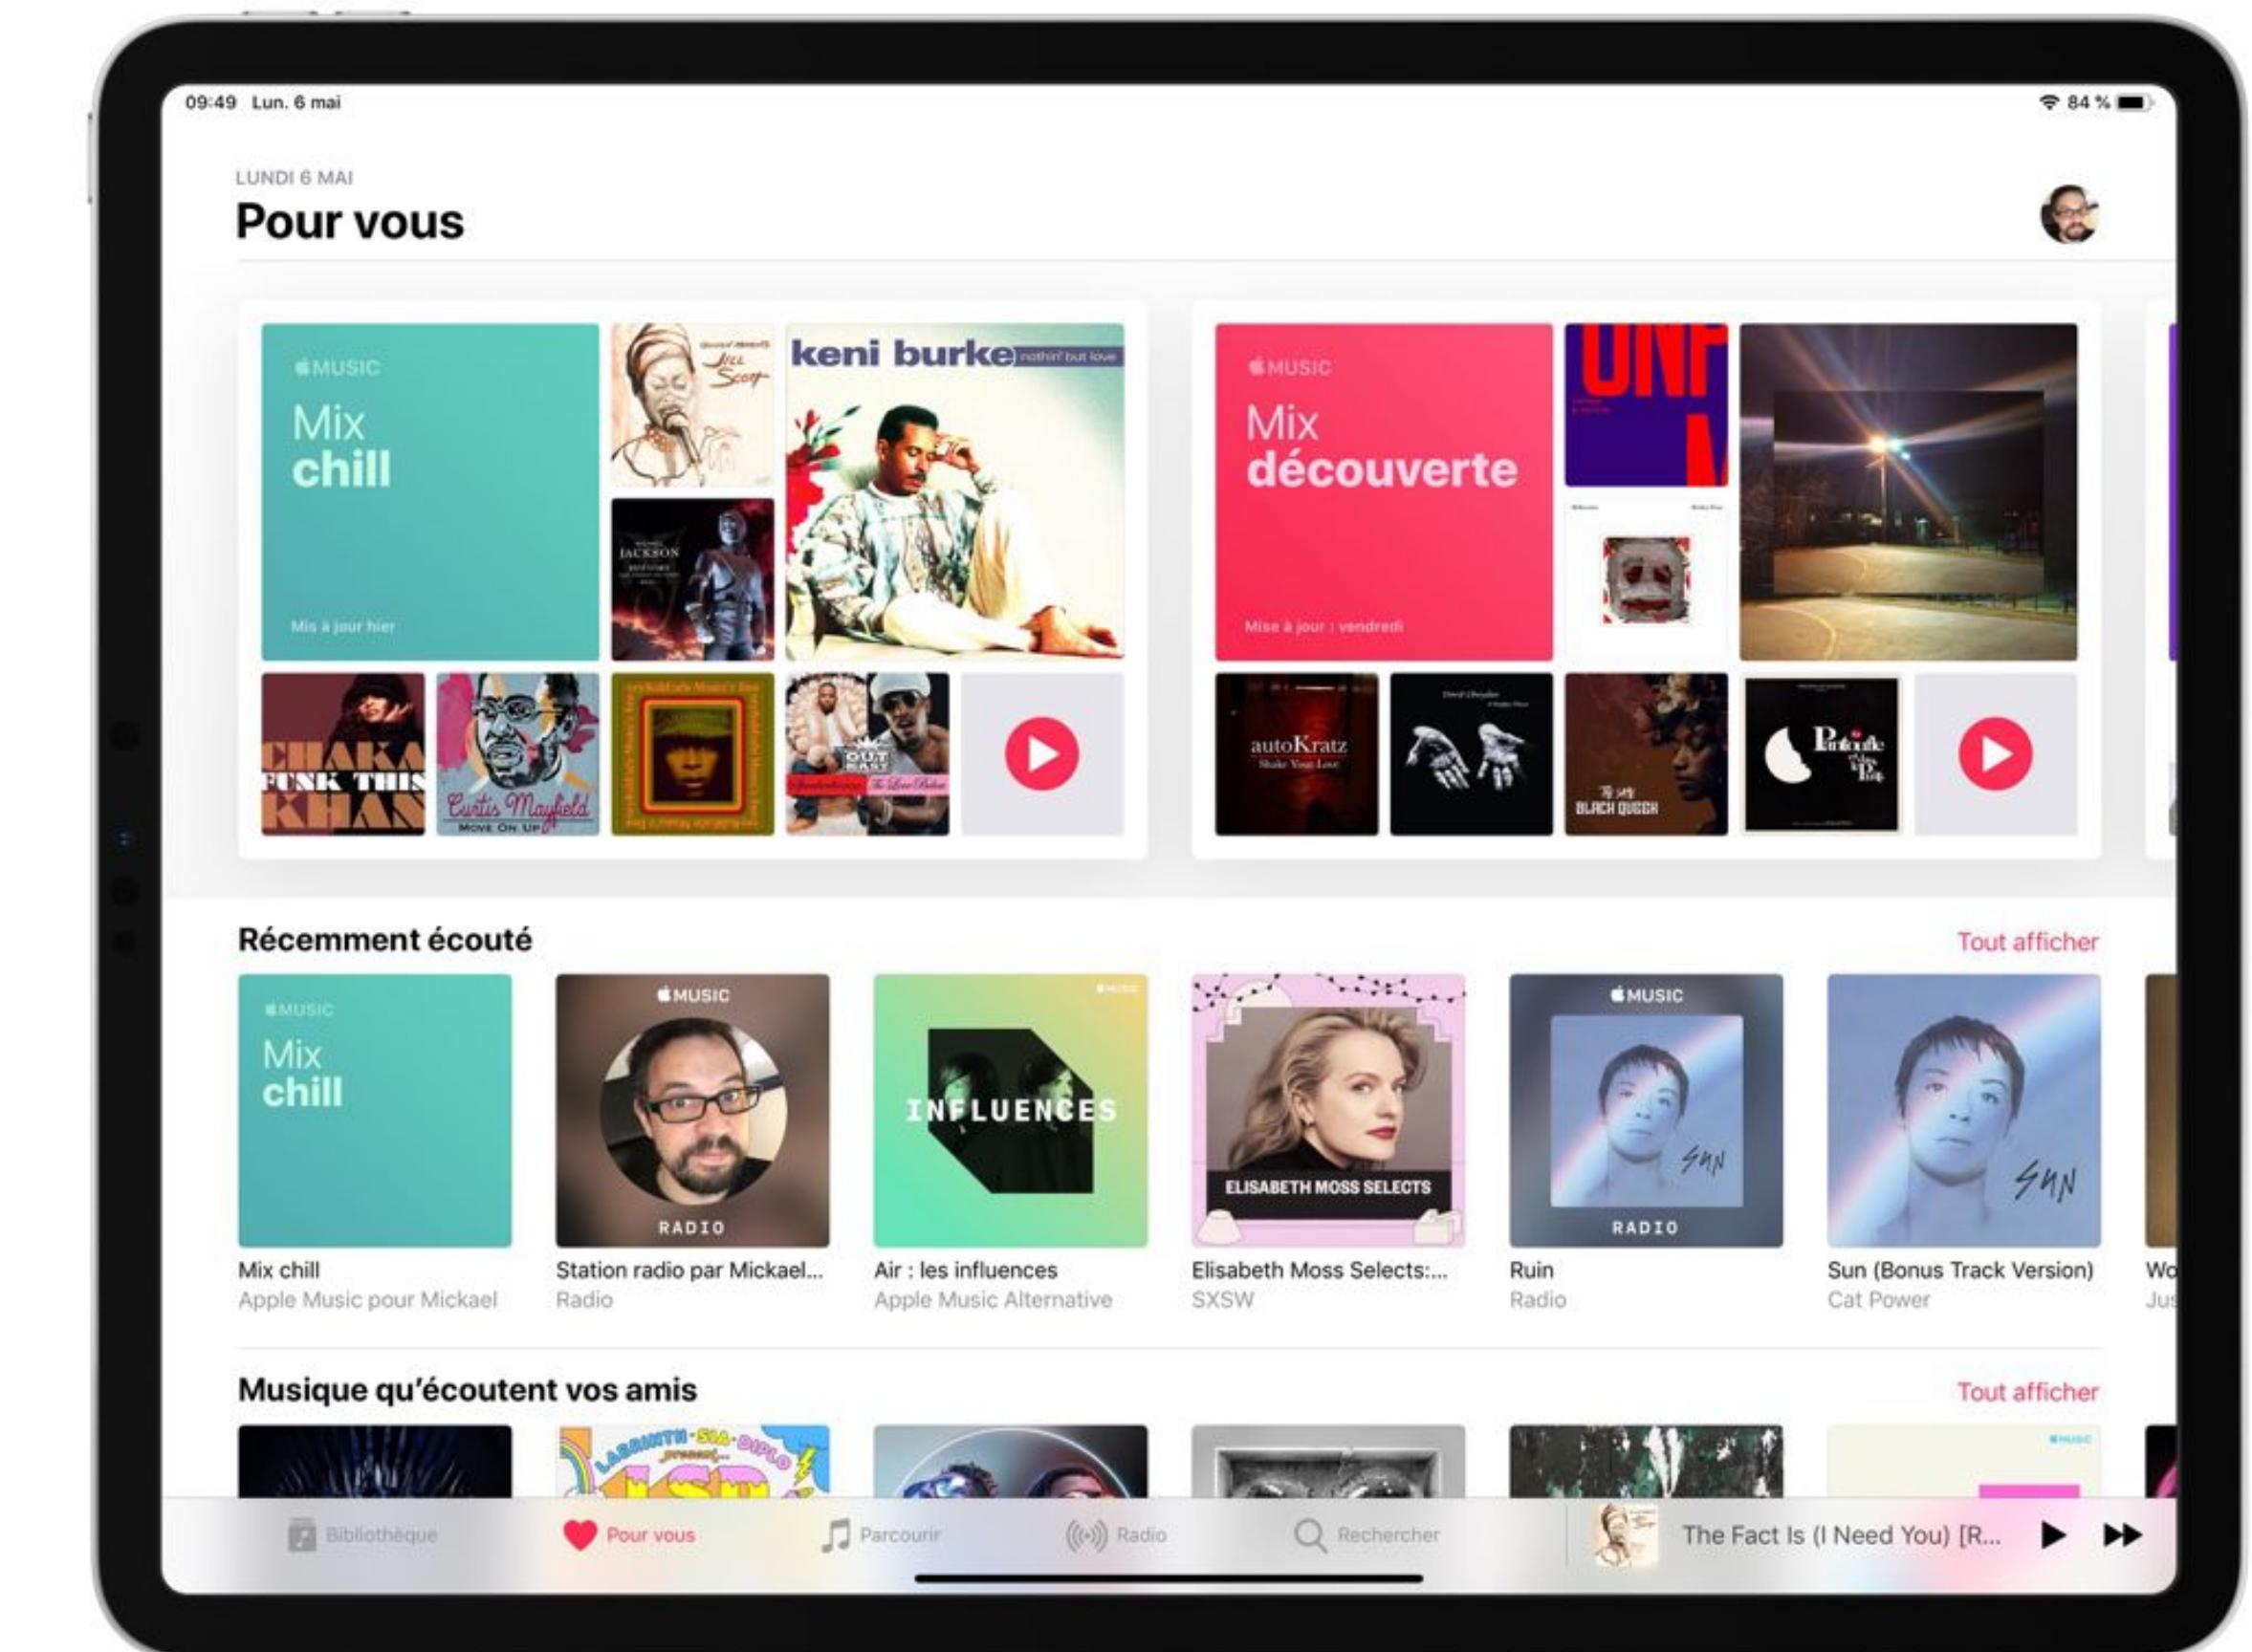
As for the previous movies of Tarantino, I was bored all along the movie. The script was quite complicated to follow up with several references to past events you should know about before. Must not see movie, pass by your way.



Application du machine learning

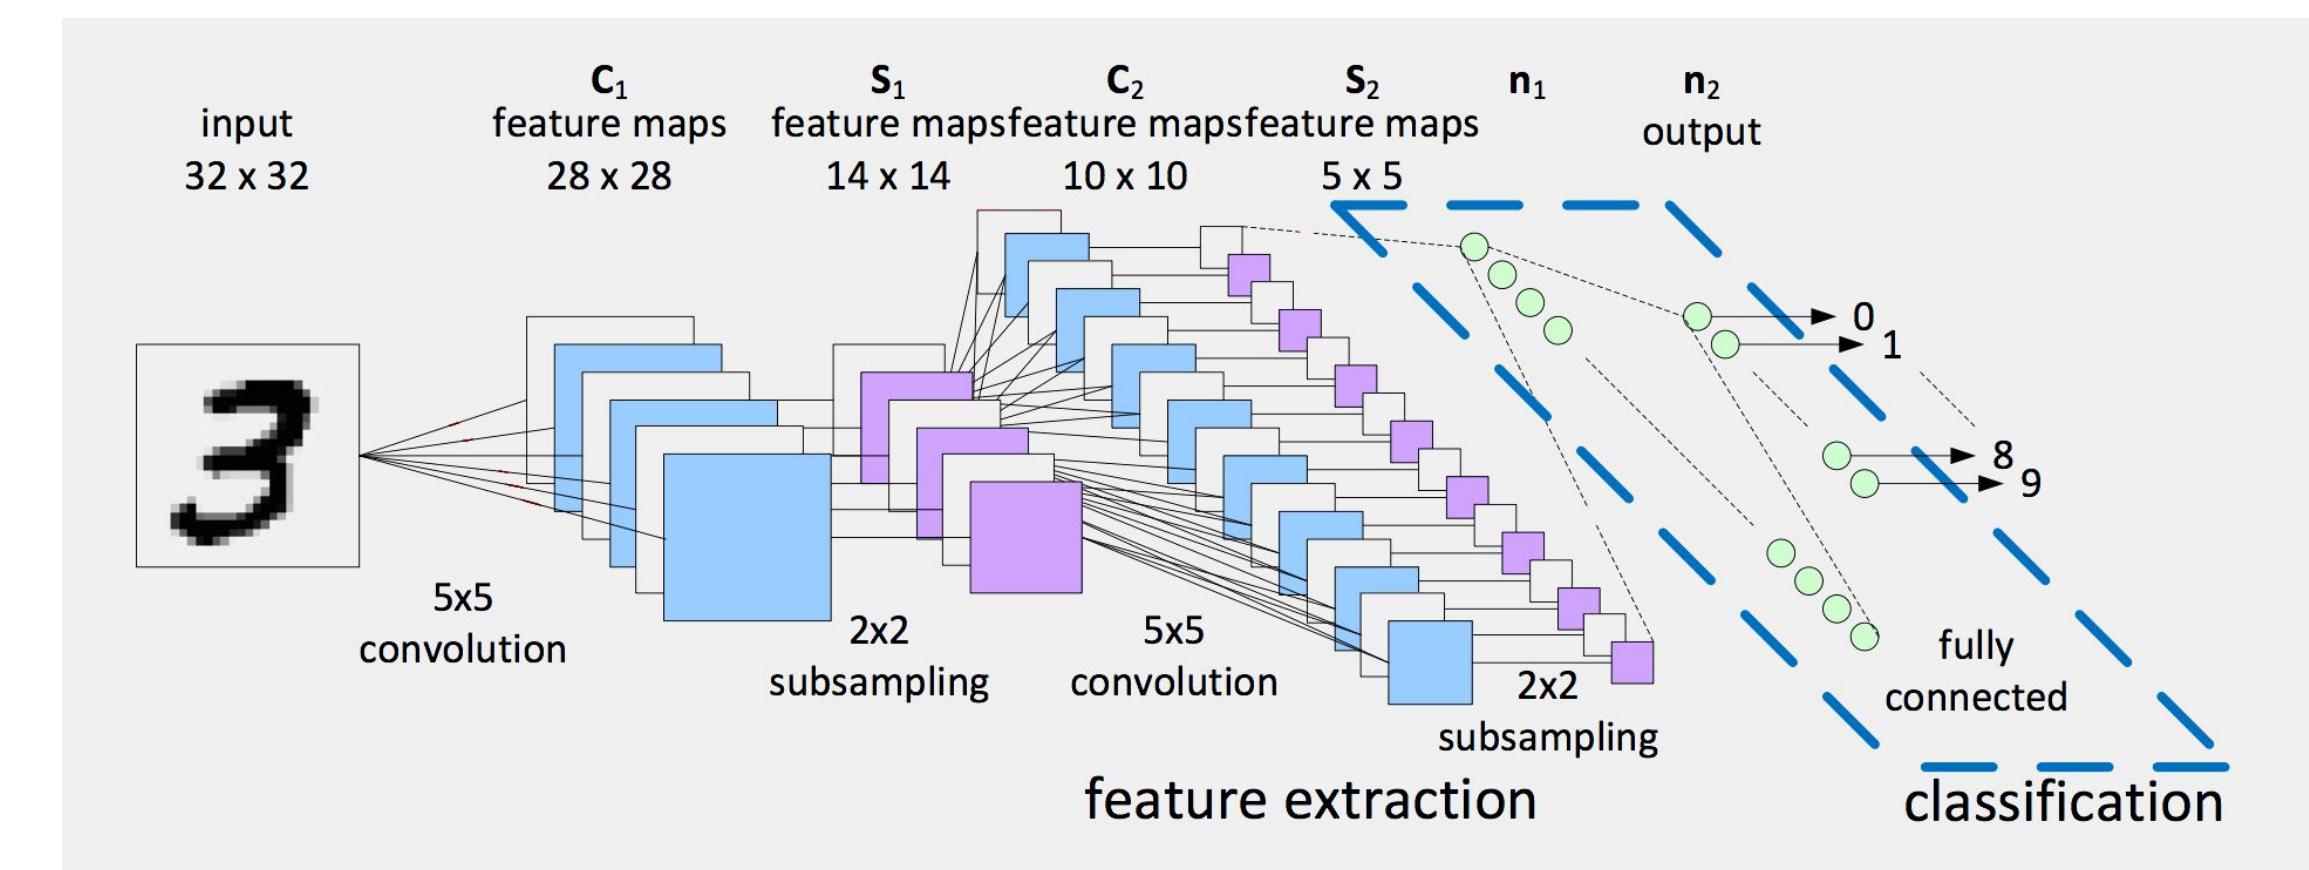
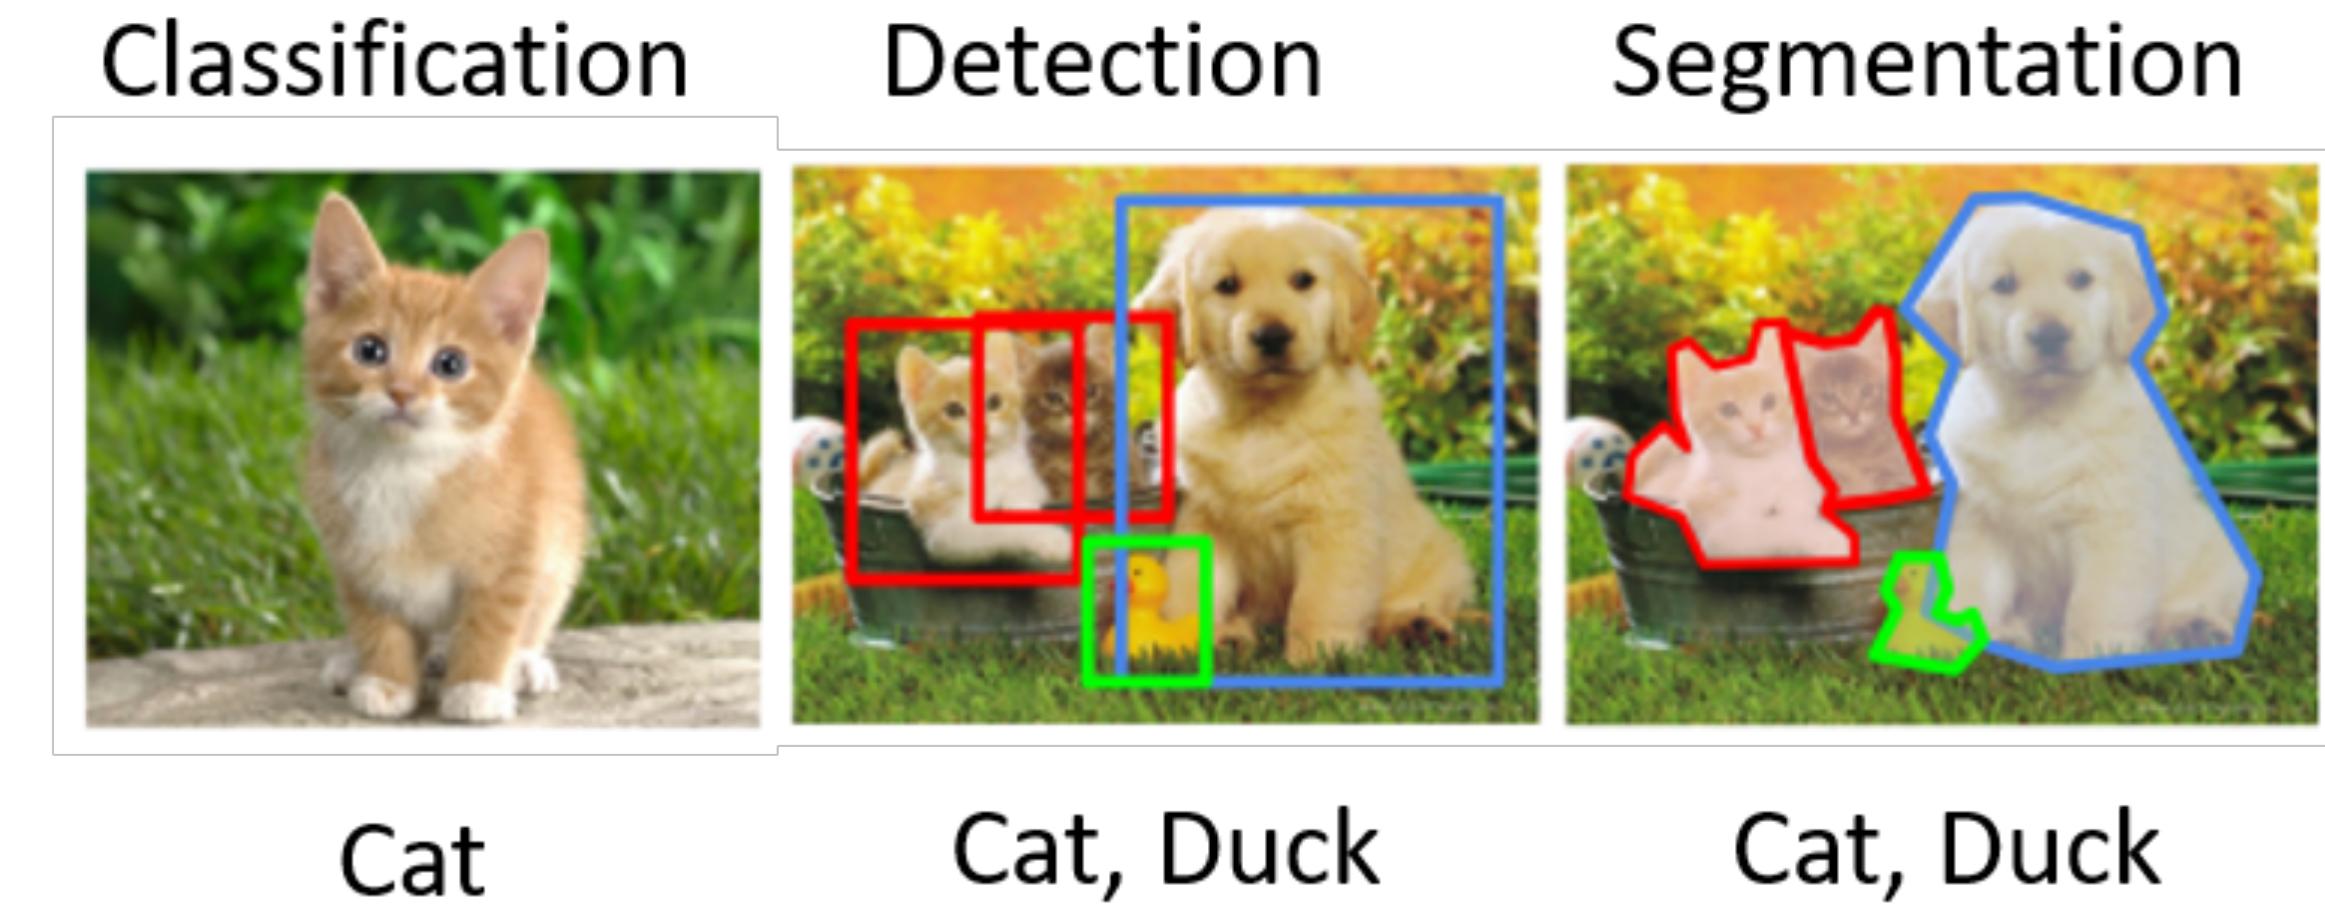
Recommandation de produit

- Proposer de nouveaux produits en fonction des caractéristiques des personnes
 - Données réseaux sociaux,
 - Historiques de navigation,
 - Etc.



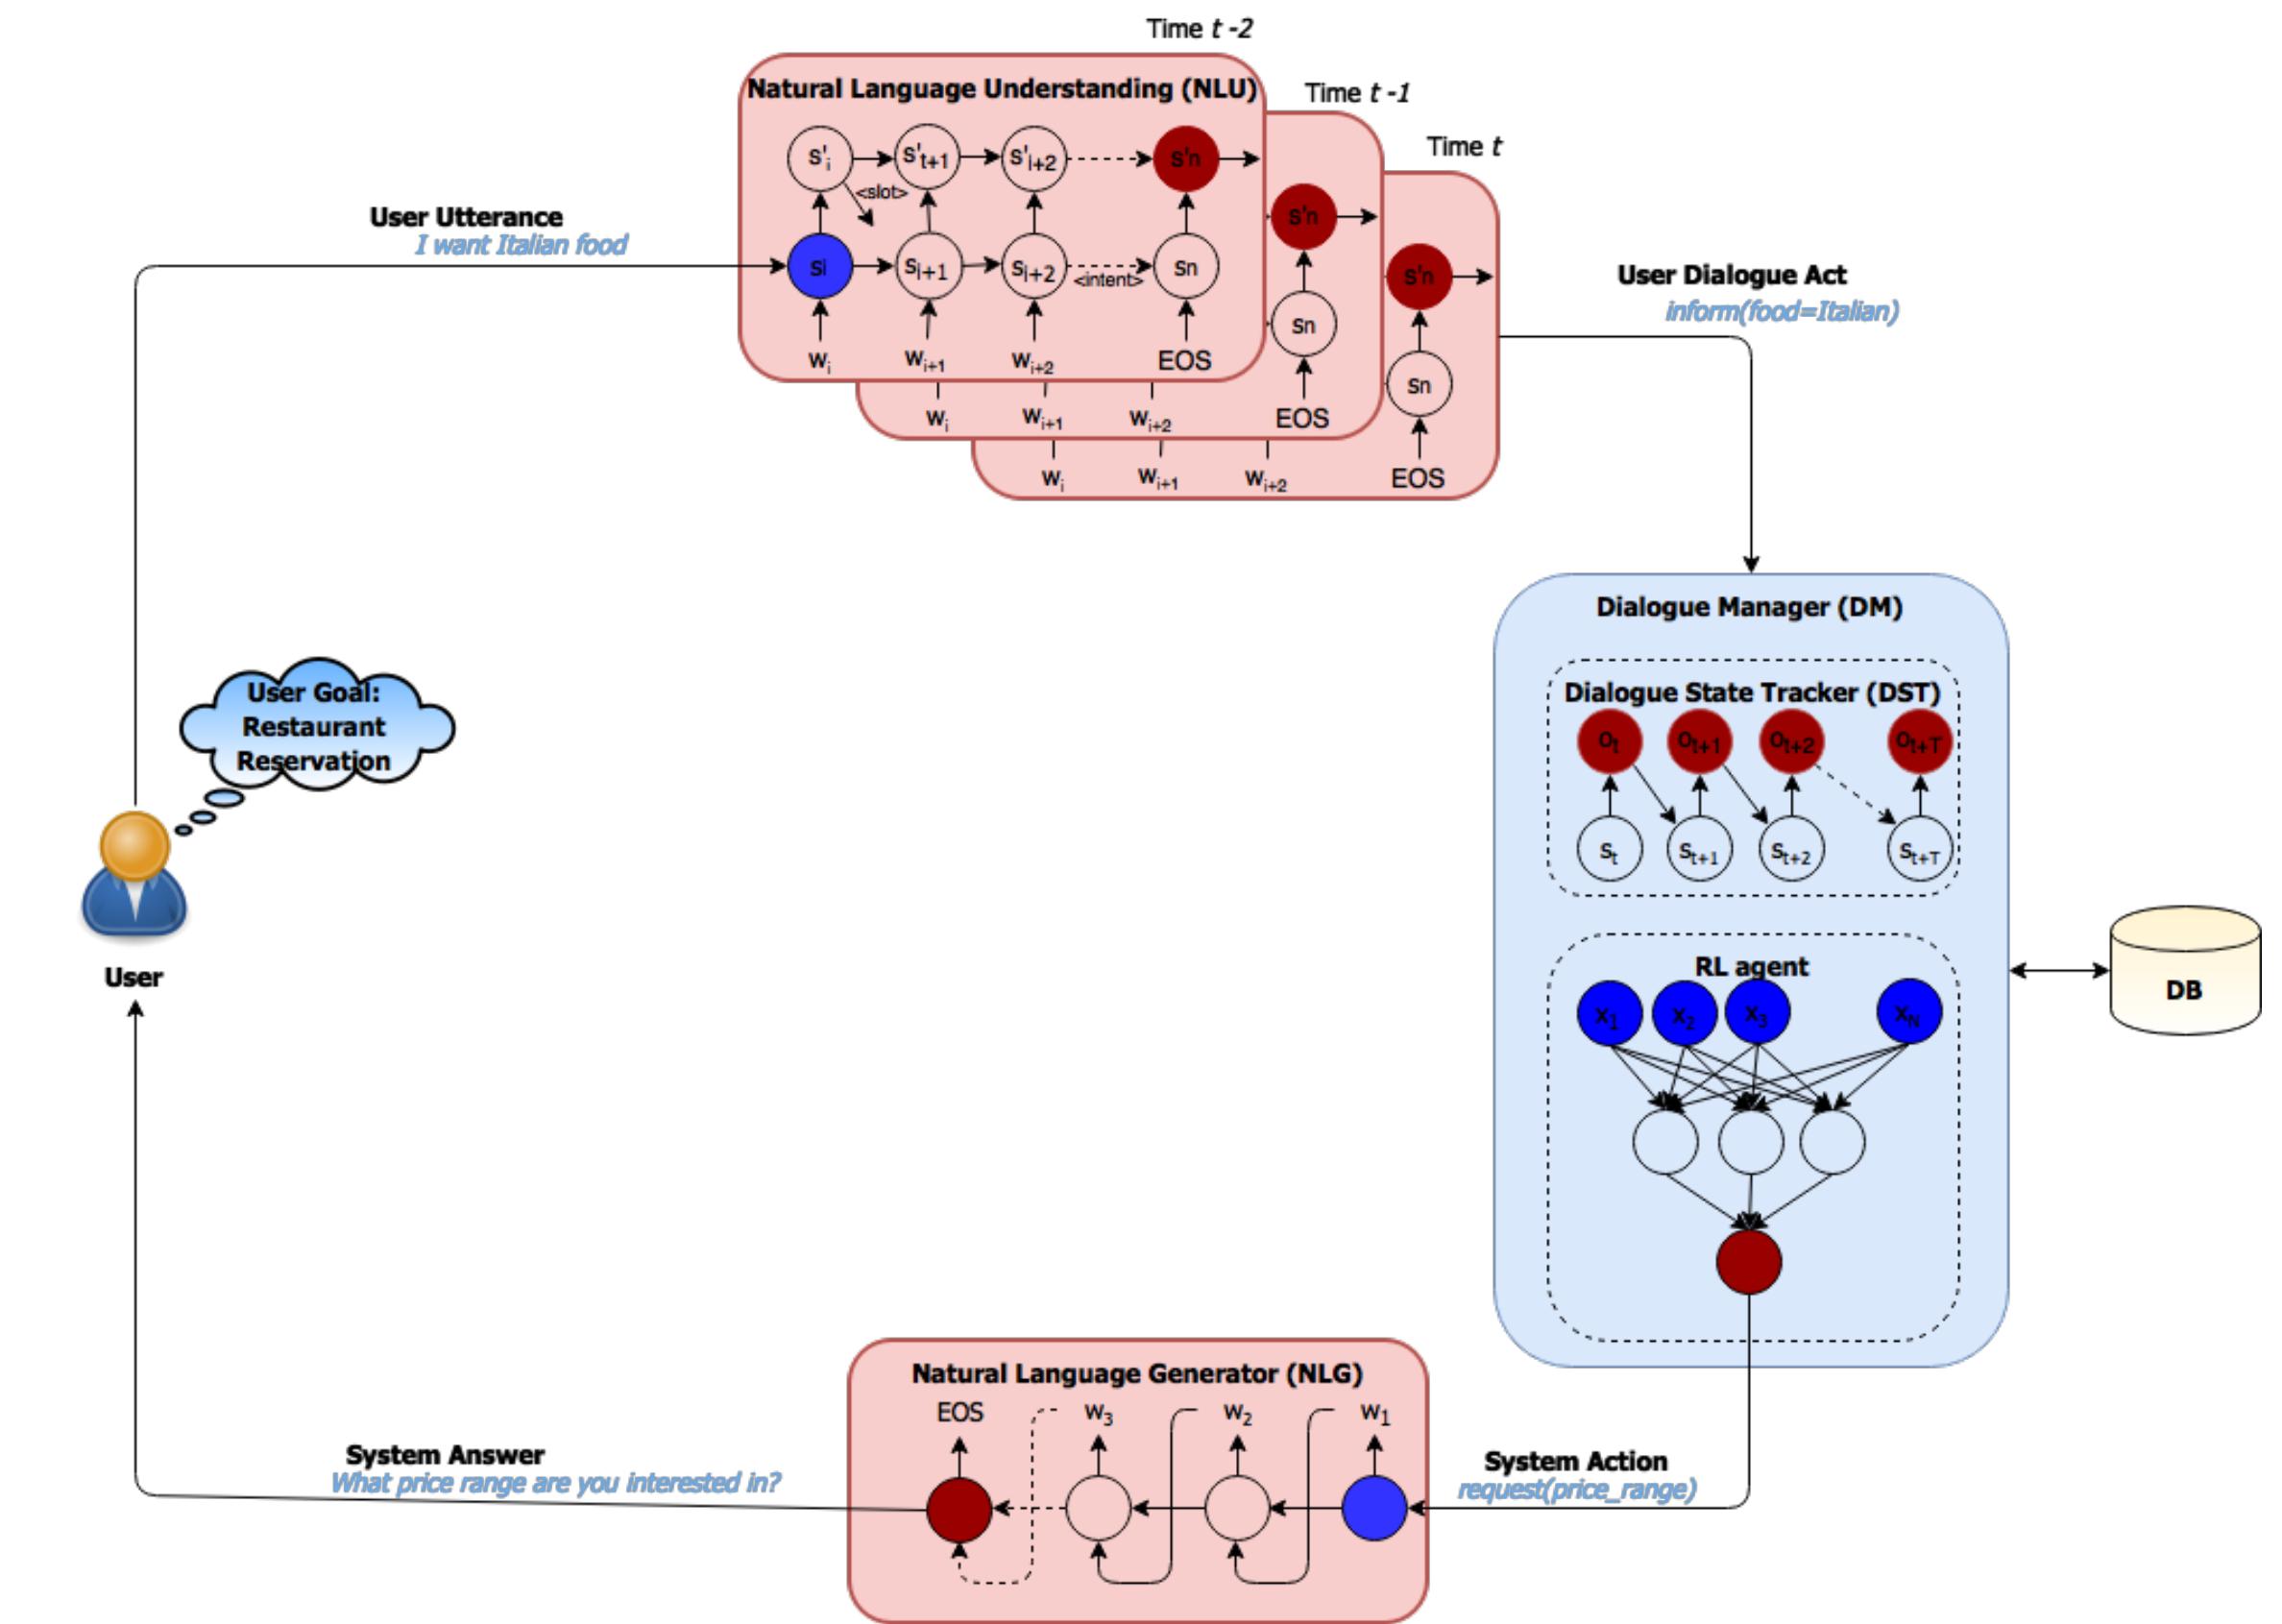
Application du machine learning

Analyse d'image



Application du machine learning Chatbot

- Traitement et Analyse du Langage (TAL ou NLP en anglais)
- Génération de texte (chatGPT)



Machine Learning ≠ Intelligence artificielle



AAAI-22 Keywords

Submission Groups

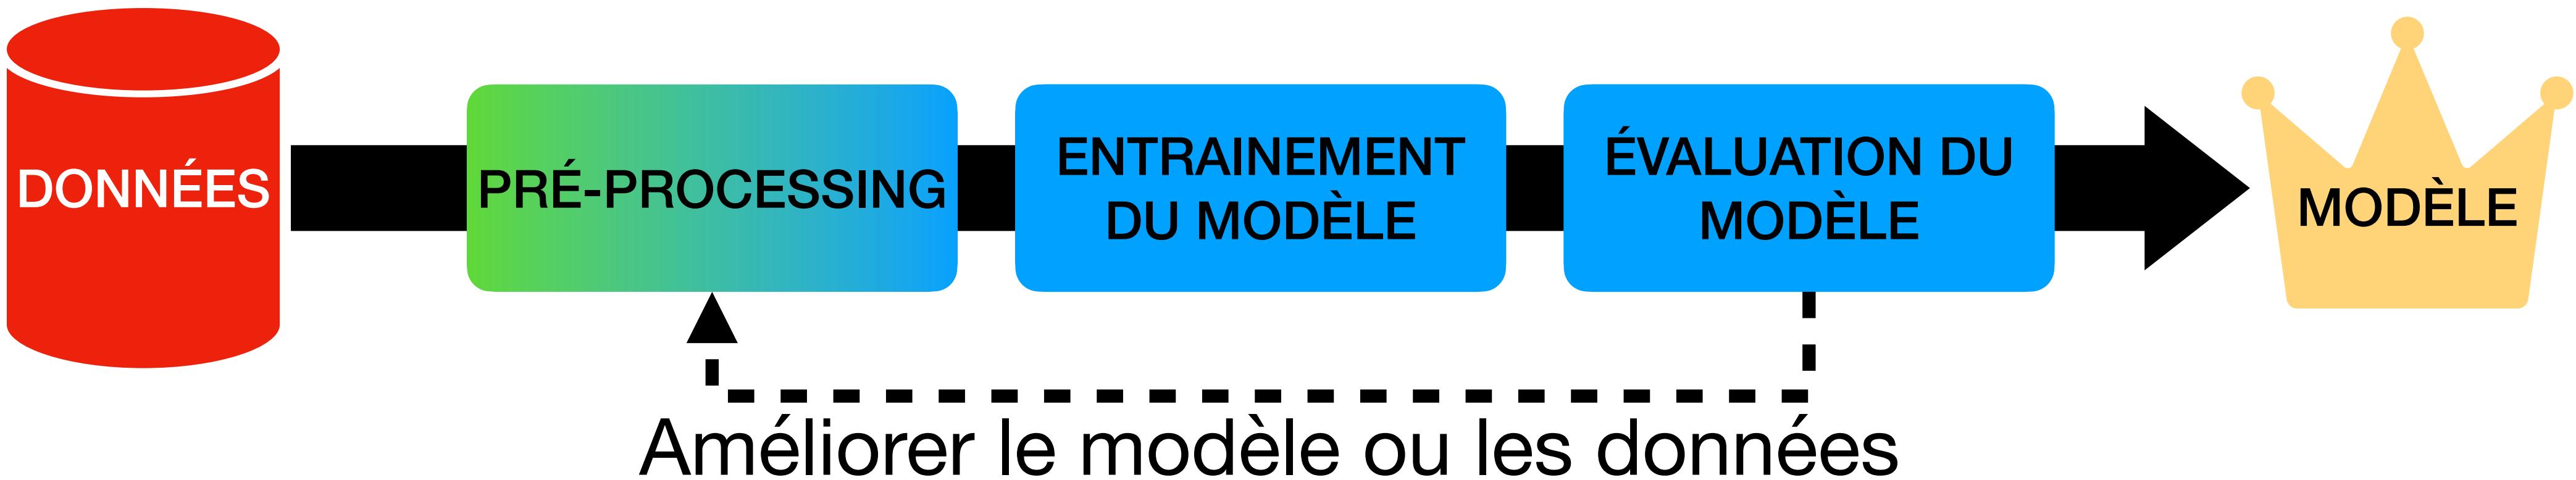
- Cognitive Modeling & Cognitive Systems (CMS)
- Computer Vision (CV)
- Constraint Satisfaction and Optimization (CSO)
- Data Mining & Knowledge Management (DMKM)
- Game Theory and Economic Paradigms (GTEP)
- Humans and AI (HAI)
- Intelligent Robotics (ROB)
- Knowledge Representation and Reasoning (KRR)
- Machine Learning (ML) (ML)
- Multiagent Systems (MAS)
- Philosophy and Ethics of AI (PEAI)
- Planning, Routing, and Scheduling (PRS)
- Reasoning under Uncertainty (RU)
- Search and Optimization (SO)
- Speech & Natural Language Processing (SNLP)
- Domain(s) of Application (APP)

Comment implémenter un projet de ML ?



Processus d'ingénierie des données

- Objectifs : obtenir un **modèle** représentatif des données pour
 - Analyser/Comprendre les données
 - Aider à la prise de décision en prédisant les données à venir



Processus d'ingénierie des données



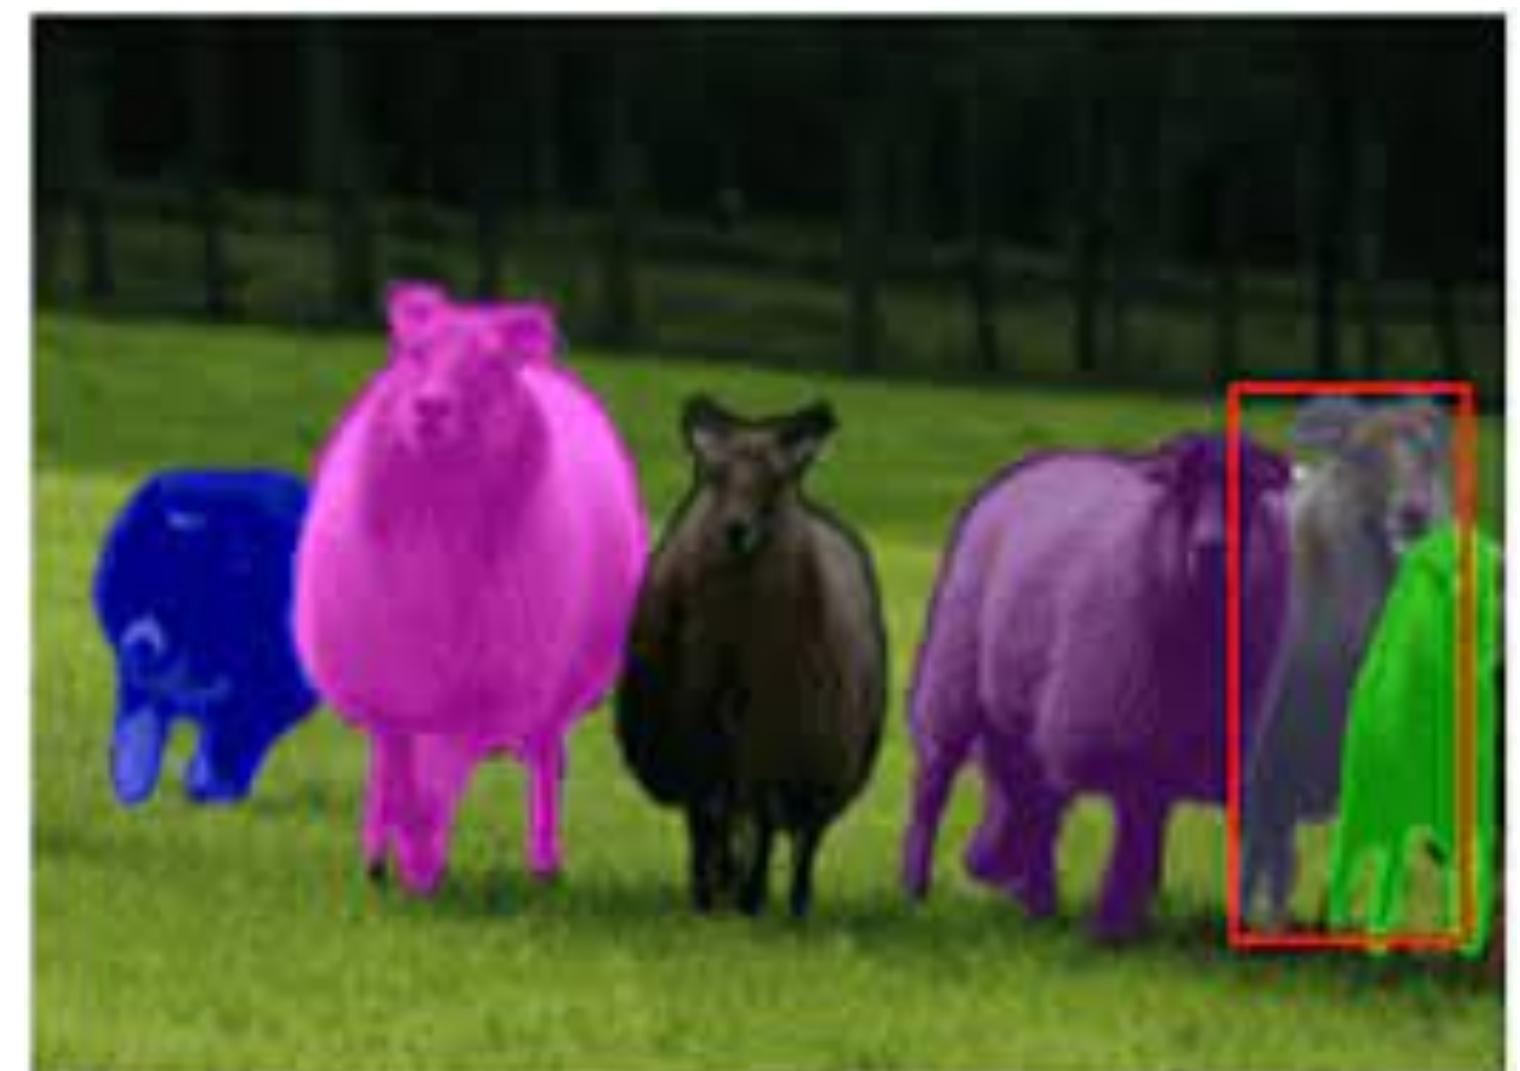
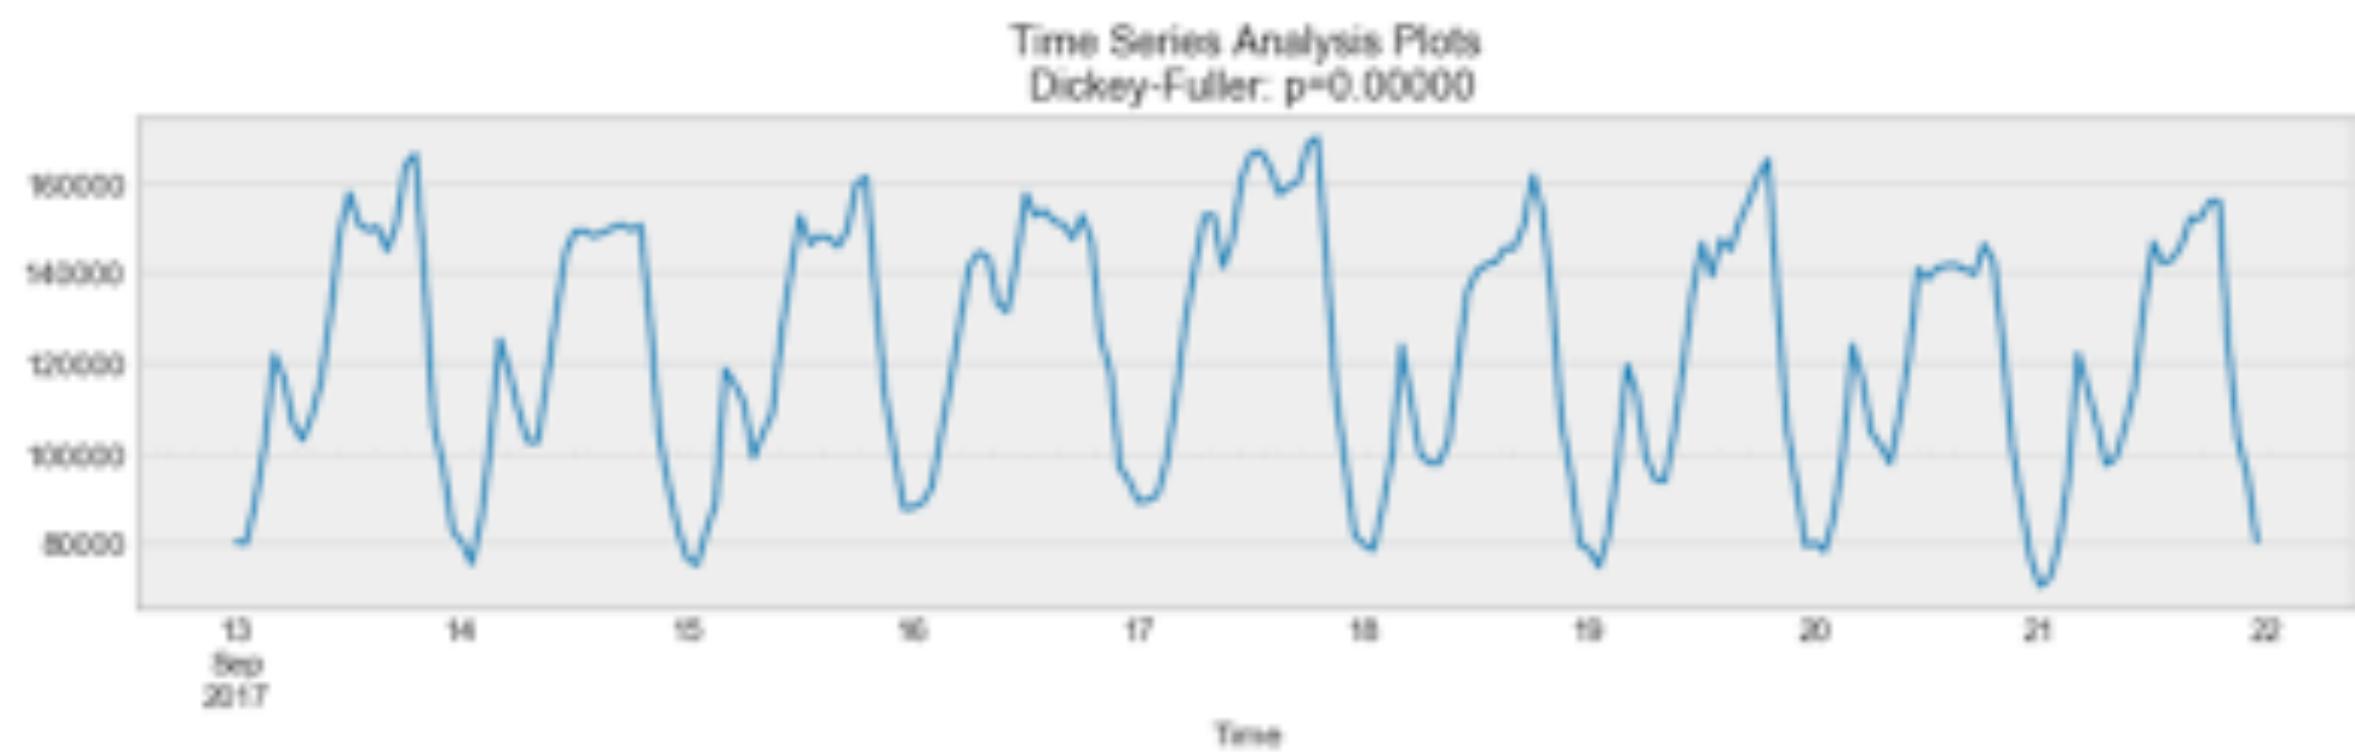
- Questions à se poser :
 - Quels sont les besoins/objectifs du client ?
 - A quel type de problème ML a-t-on affaire ?
 - Quel algorithme de ML utiliser ?
 - Quels sont les meilleurs paramètres pour cet algorithme ?
 - Comment évaluer la performance du modèle ?
 - Quel est l'impact de ce modèle pour la société ?
 - Etc.

Les données

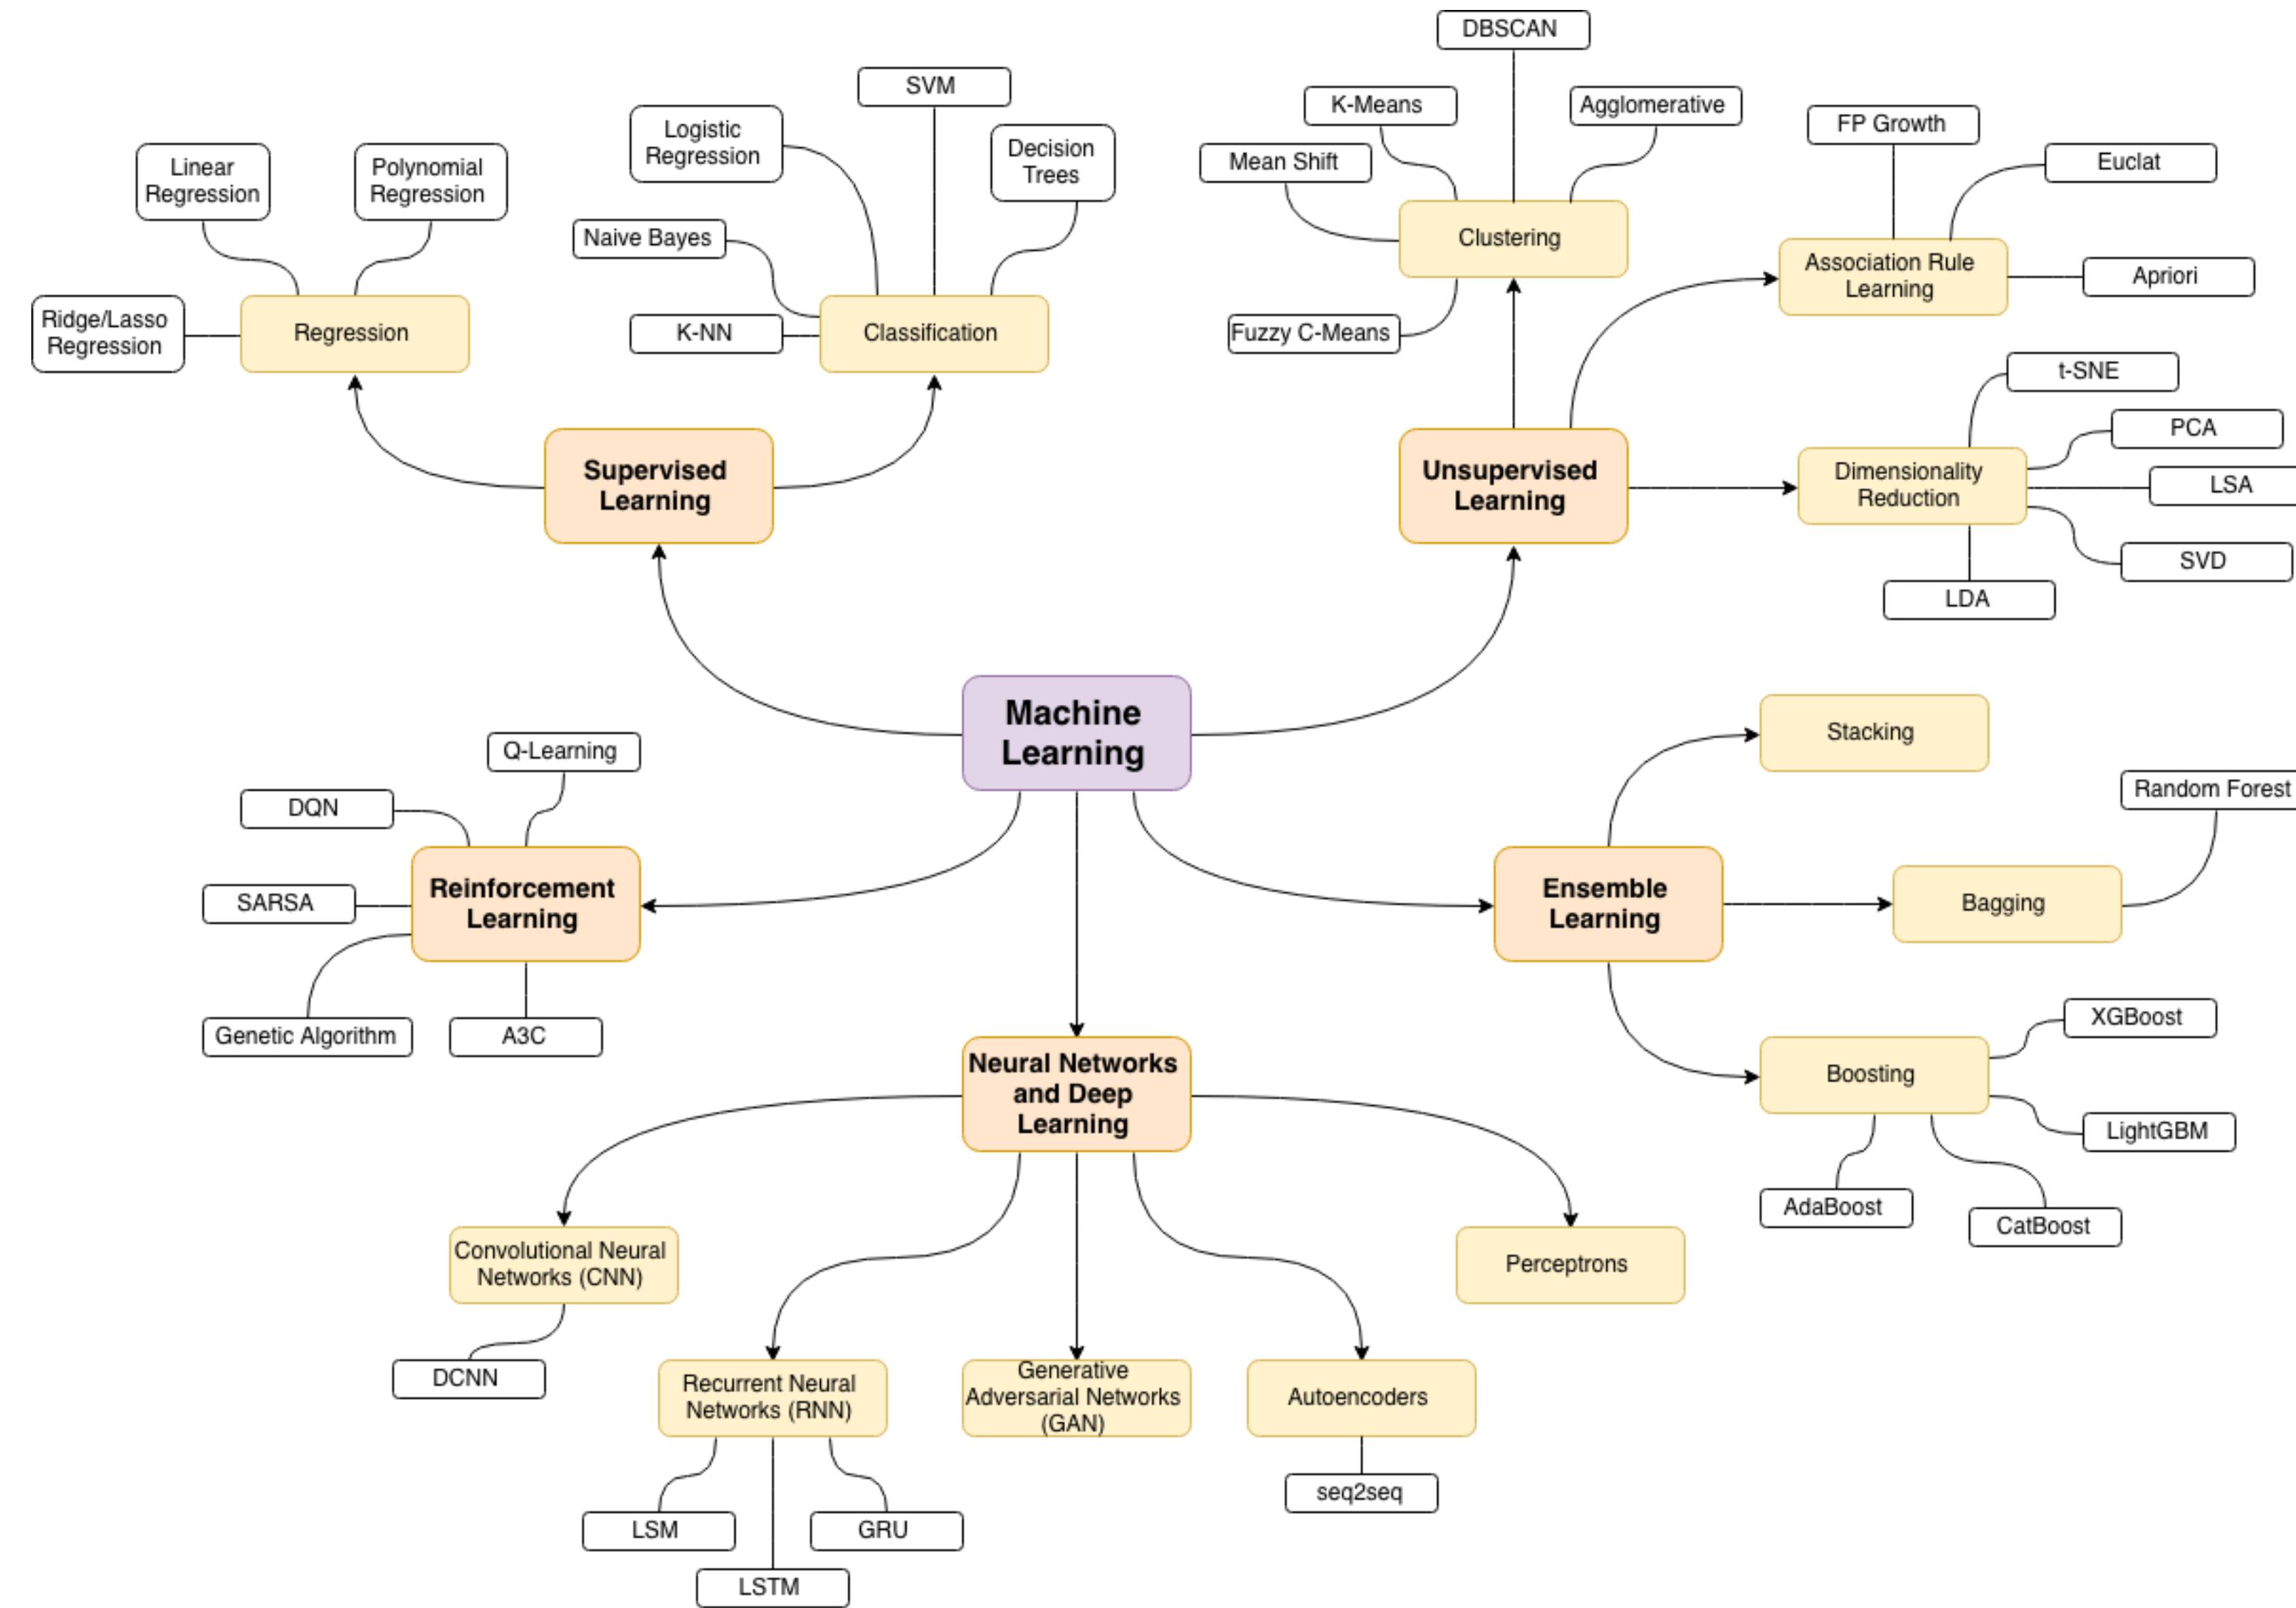
- Ensemble de données (data set)
 - Exemples d'expériences passées (informations) avec des attributs.
 - Un data set est constitué de N exemples (samples).
- Attributs
 - Un attribut est une caractéristique (feature) ou propriété d'un phénomène observé.
 - On parle aussi de variable.
- Exemple (sample)
 - C'est un ensemble d'attributs caractérisant un objet.
 - On parle aussi d'instance, de point ou de vecteur (souvent dans \mathbb{R}^d)

Types de données

- Capteurs :
 - Variables quantitatives et qualitatives
 - Données ordinales (échelles, intervalles, etc.)
 - Données nominales (genre, choix multiples, etc.)
- Texte : Chaîne de caractères
- Parole : Série temporelle (time series)
- Image : Donnée 2D
- Vidéo : Donnée 2D + temps
- Réseau : Graphes
- Flux : logs, tickets, etc.



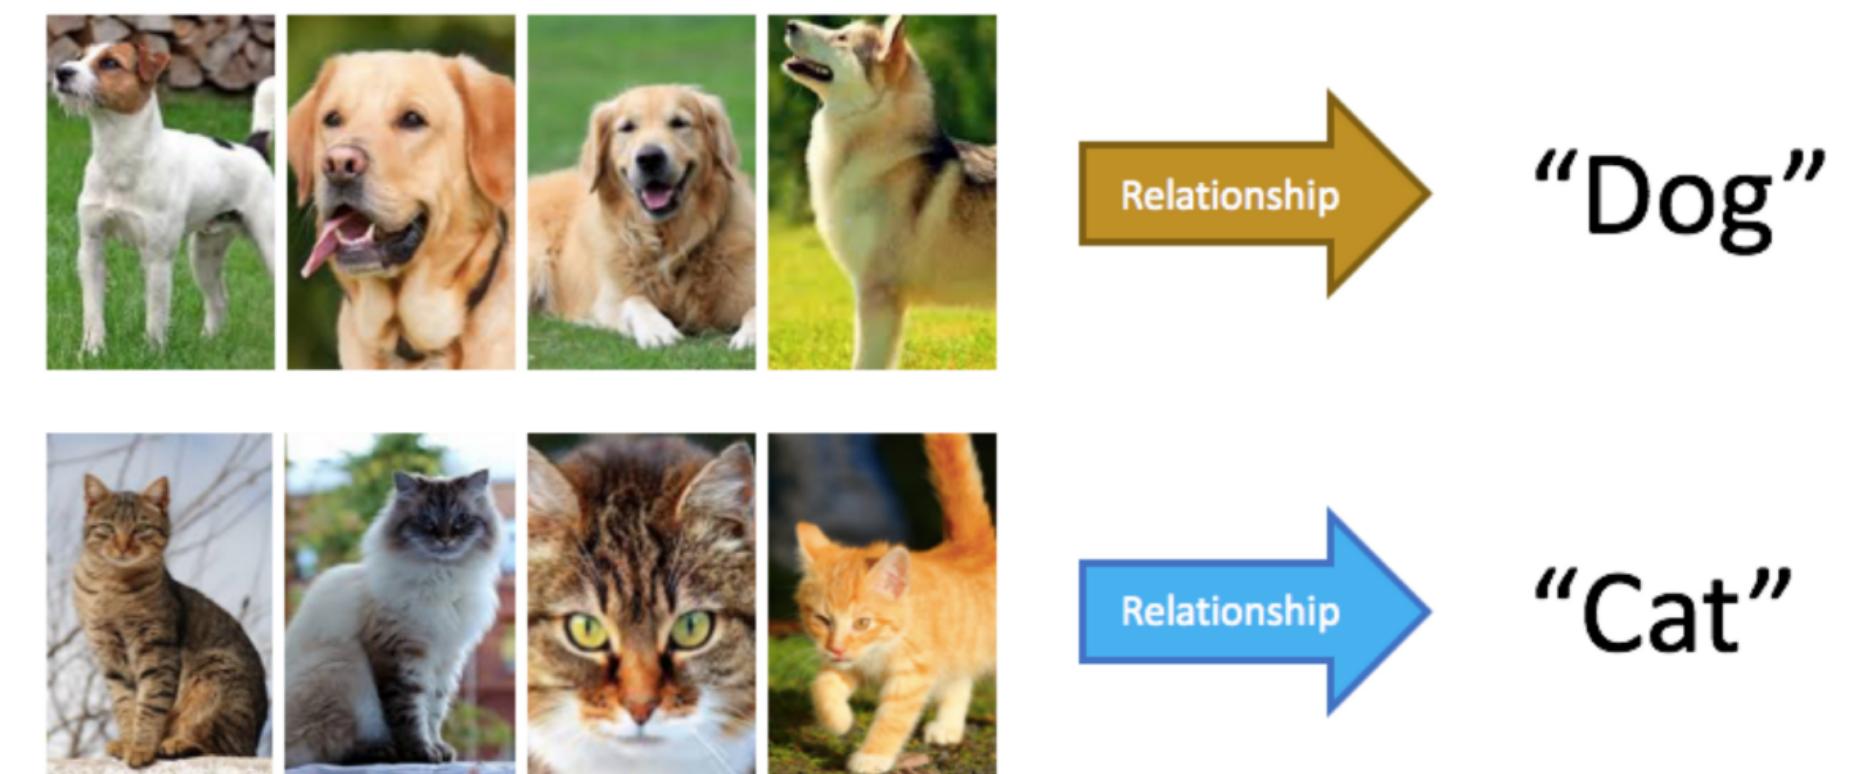
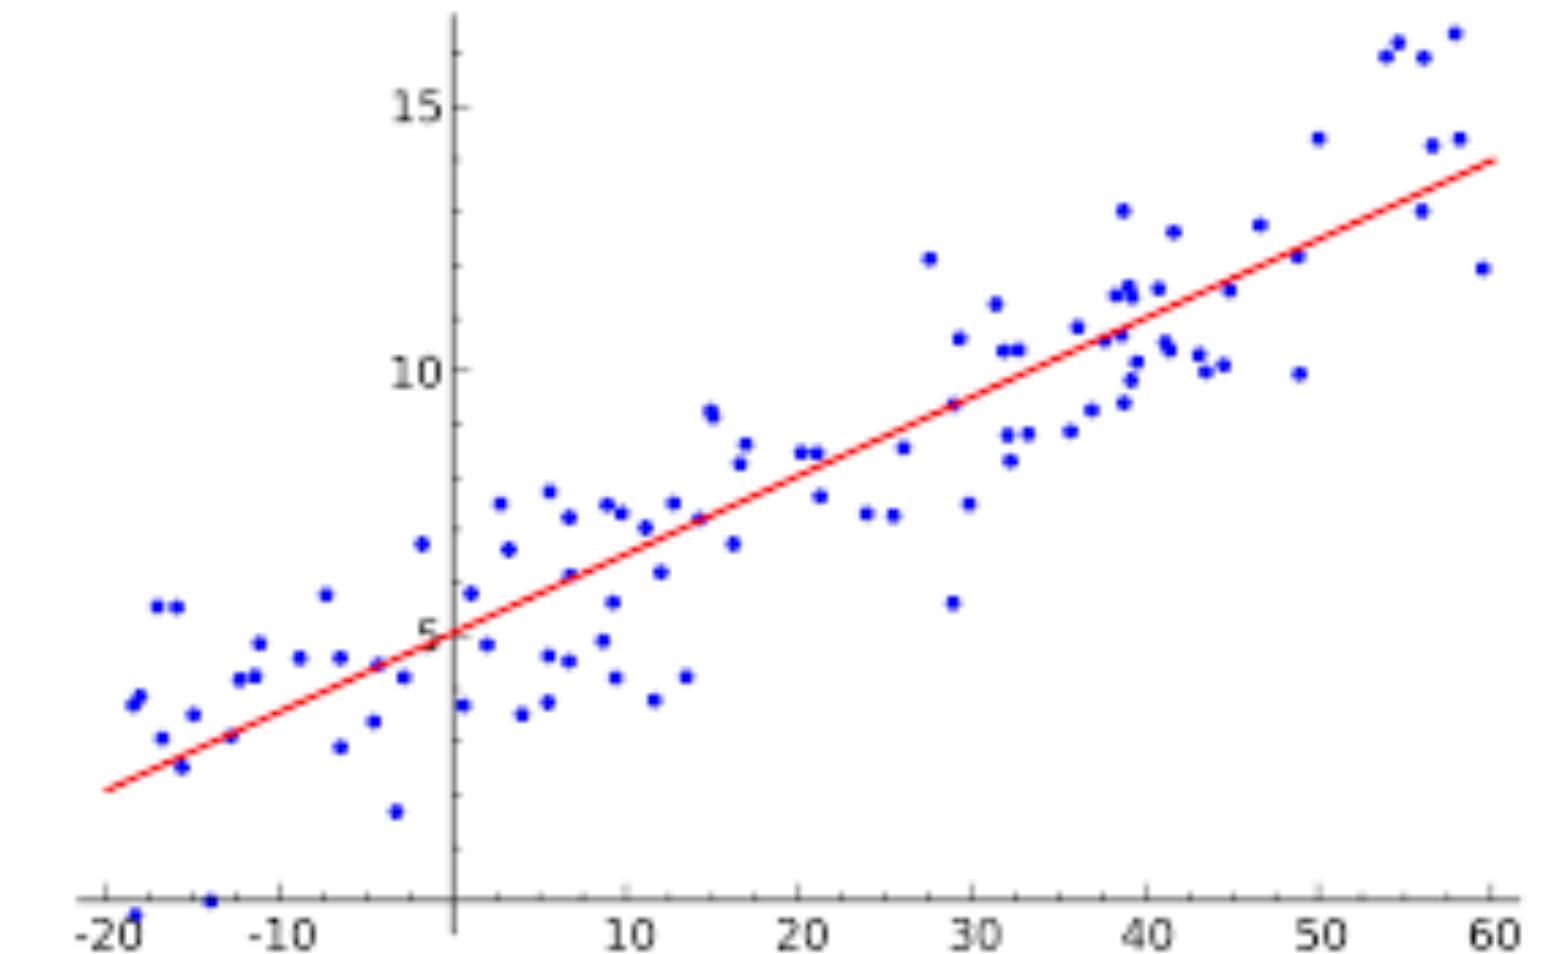
Les différentes approches de ML



Apprentissage supervisé

Définition

- Principe
 - Etant donné un ensemble de N exemples d'entraînement $\{(x_i, y_i) \in \mathcal{X} \times \mathcal{Y}, i = 1..N\}$, on cherche une fonction de prédiction telle que $y = f(x)$
 - L'apprentissage est supervisé car les labels y sont connus
- Exemples
 - Classification d'images
 - Prédiction météo (température), stock, etc.

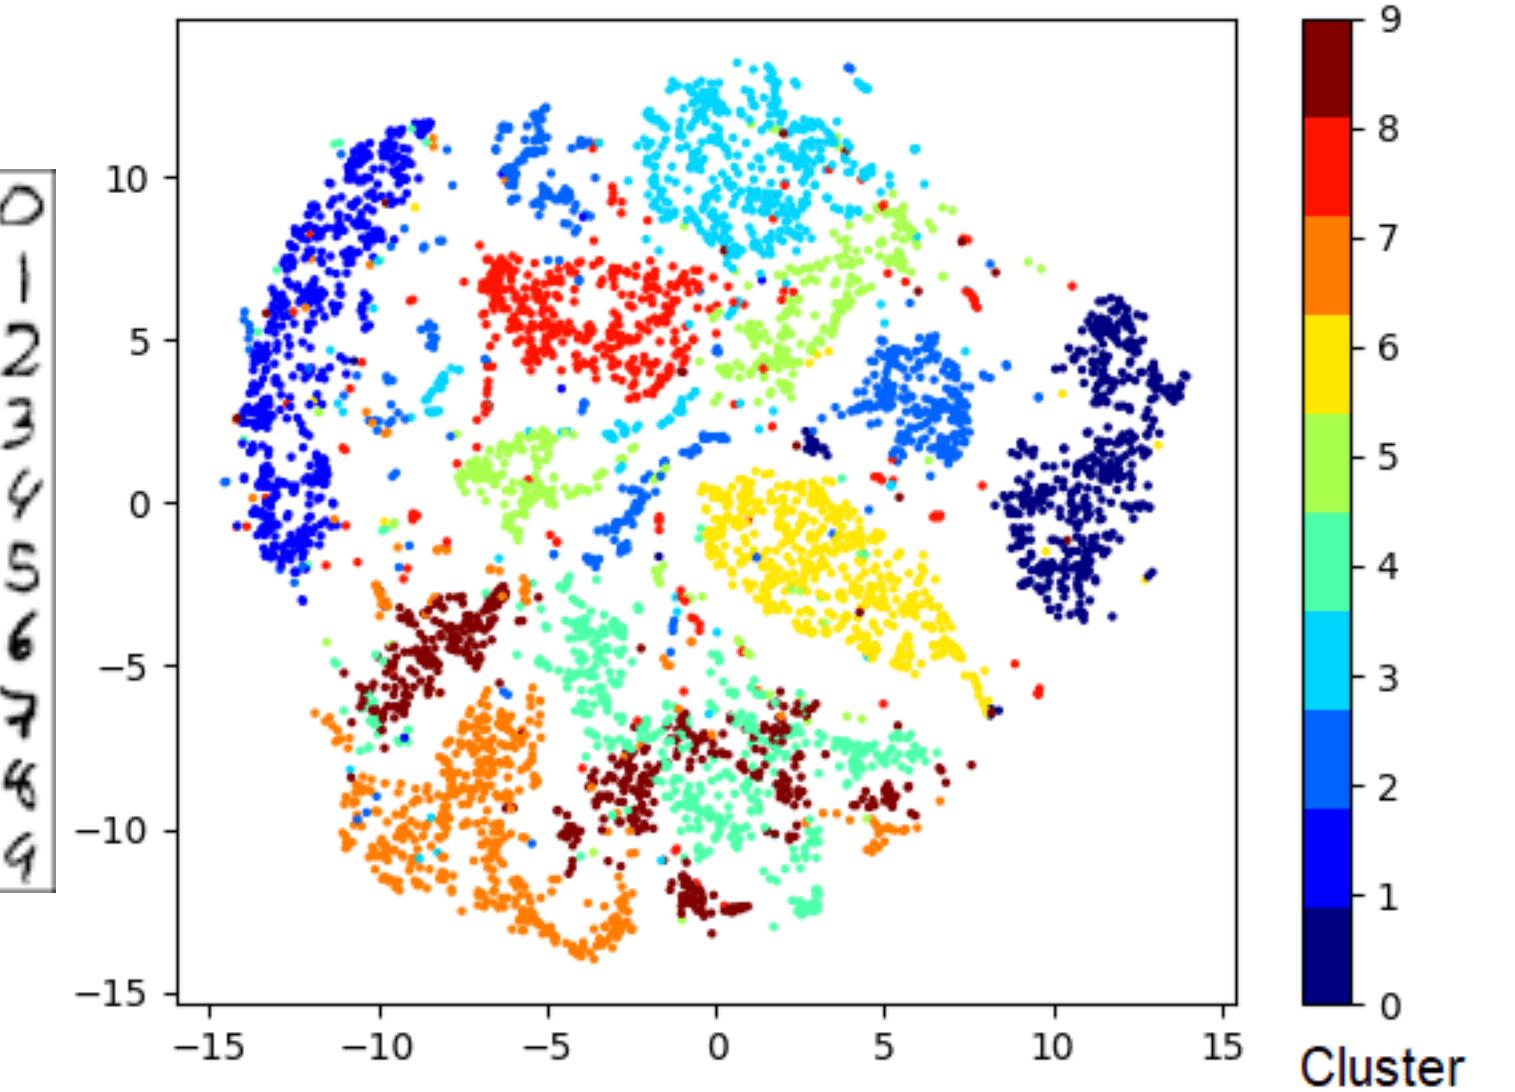


Apprentissage non-supervisé

Définition

- Principe :
 - Seul les caractéristiques $\{x_i \in \mathcal{X}, i = 1..N\}$ sont disponibles.
 - On cherche à décrire comment les données sont **organisées** et extraire les **sous-ensemble homogènes**.
- Exemple :
 - Reconnaissance des formes
 - Analyse spatiales
 - Catégorisation de documents
 - Catégorisation d'usage (web, personnalisation, etc.)

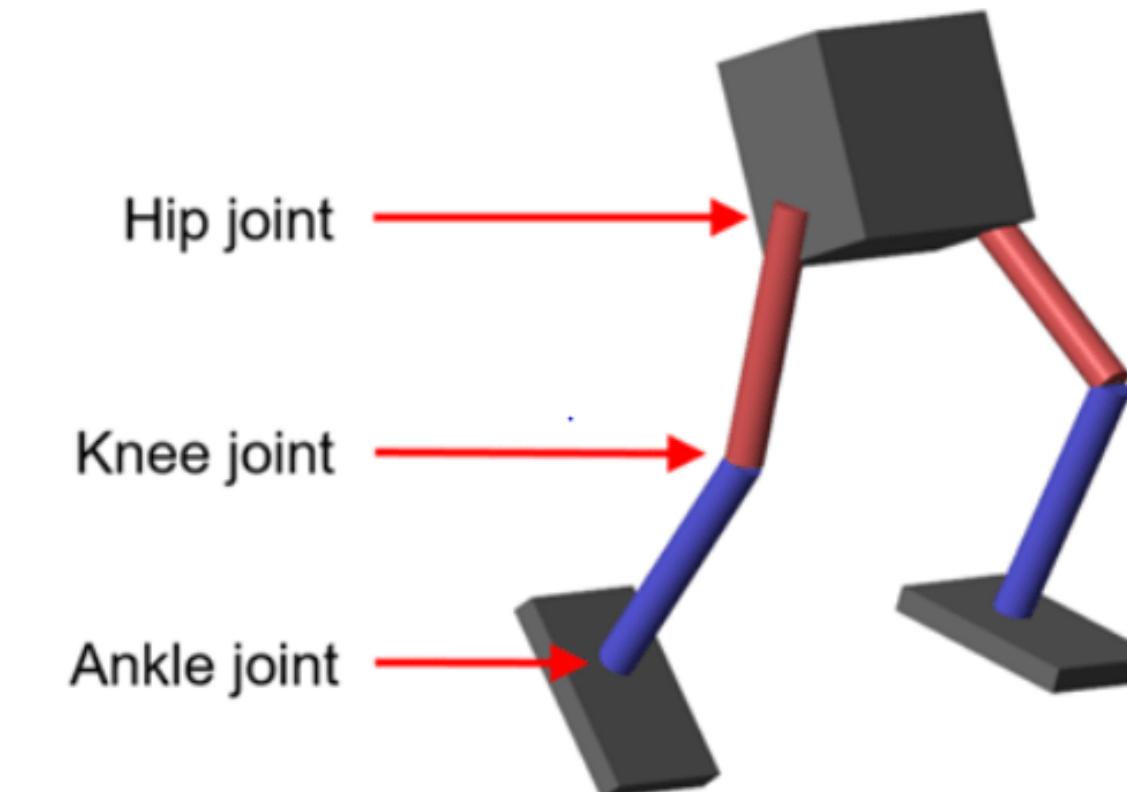
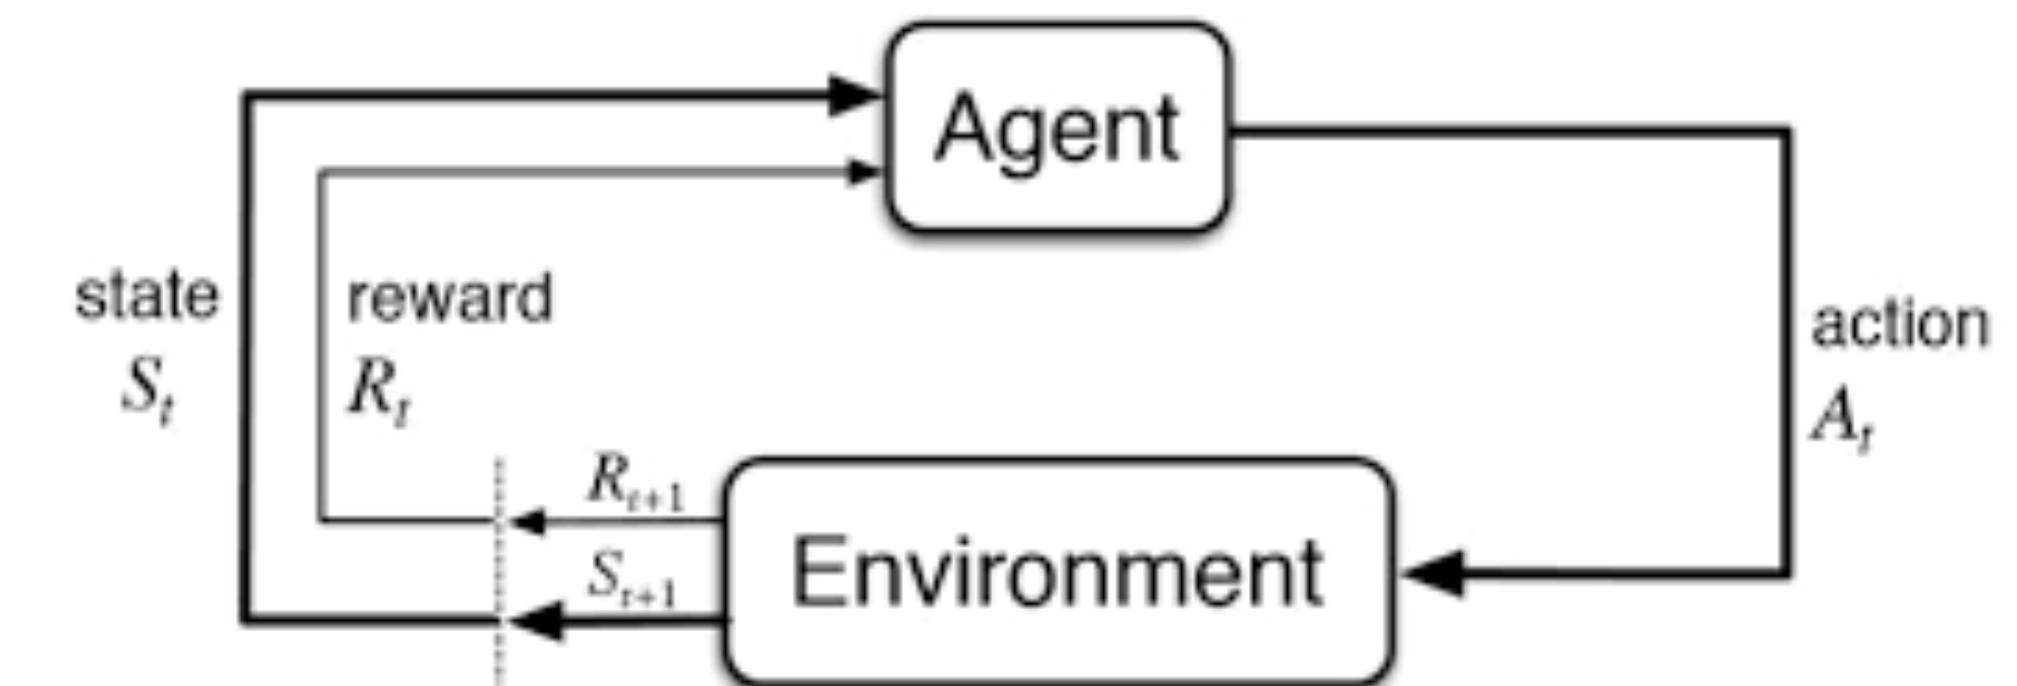
000000000000000000
111111111111111111
222222222222222222
333333333333333333
444444444444444444
555555555555555555
666666666666666666
777777777777777777
888888888888888888
999999999999999999



Apprentissage par renforcement

Définition

- Principe
 - Pas de supervision, seulement une **récompense** (reward)
 - Le feedback n'est pas instantané
 - Le temps est crucial
 - Les actions affectent les données à venir
- Exemple
 - Jeu vidéo
 - Robotique
 - Personnalisation de contenu



- A quel type d'apprentissage avons-nous à faire pour le dataset IRIS?

[Lien vers le notebook](#)